



ΠΑΝΕΠΙΣΤΗΜΙΟ ΠΑΤΡΩΝ  
ΠΟΛΥΤΕΧΝΙΚΗ ΣΧΟΛΗ  
ΤΜΗΜΑ ΜΗΧΑΝΙΚΩΝ ΗΛΕΚΤΡΟΝΙΚΩΝ ΥΠΟΛΟΓΙΣΤΩΝ ΚΑΙ  
ΠΛΗΡΟΦΟΡΙΚΗΣ

Διατμηματικό Πρόγραμμα Μεταπτυχιακών Σπουδών  
« Συστήματα Επεξεργασίας Πληροφορίας και Μηχανική Νοημοσύνη »  
(ΔΠΜΣ-ΣΜΗΝ)

ΜΕΤΑΠΤΥΧΙΑΚΗ ΔΙΠΛΩΜΑΤΙΚΗ ΕΡΓΑΣΙΑ  
ΚΑΦΤΑΝΗΣ ΓΕΩΡΓΙΟΣ

«Εκτίμηση ευθραυστότητας και δυσμενών γεγονότων  
με την χρήση δεδομένων κίνησης και συμπεριφοράς»

Επιβλέπων: Βασίλειος Μεγαλοοικονόμου

Πάτρα, Σεπτέμβριος 2023



## ΠΕΡΙΛΗΨΗ

Η παρούσα διπλωματική στοχεύει στην ανασκόπηση του προγράμματος Frail Safe, μέσω της συγκέντρωσης όλων των ερευνών και εργασιών που έχουν πραγματοποιεί σχετικά με αυτό. Παράλληλα, γίνεται προσπάθεια για υλοποίηση νέων μεθόδων, οι οποίες διαφοροποιούνται από τις ήδη υπάρχουσες κυρίως όσον αφορά τις μετρήσεις και τα δεδομένα που αξιοποιούνται, αλλά και ορισμένα μοντέλα ταξινόμησης.

Στο πλαίσιο της διπλωματικής εργασίας υλοποιήθηκε μια εφαρμογή σε Python, η οποία περιλαμβάνει την κατάλληλη διεπαφή (interface) για την εκτέλεση διαφορετικών μεθόδων επεξεργασίας δεδομένων και κατηγοριοποίησης δεδομένων χρονικού παραθύρου ή δραστηριότητας σε 3 ("Non-Frail", "Pre-Frail", "Frail") ή 2 κλάσεις ("Non-Frail", "Frail"), δηλαδή με βάση τον δείκτη ευπάθειας του συμμετέχοντα.

Τα δεδομένα τα οποία αξιοποιήθηκαν περιορίζονται μόνο σε δεδομένα κίνησης και συμπεριφοράς τα οποία μπορούν να αντληθούν από ένα «έξυπνο» ρολόι ή τηλέφωνο. Αυτό αποσκοπεί στην εξαγωγή μεθόδων κατηγοριοποίησης ευπάθειας με την χρήση εύχρηστων συσκευών. Για την αντιμετώπιση του προβλήματος των μη ισορροπημένων δεδομένων δοκιμάζονται οι τεχνικές SMOTE, Tomek Links, ένας συνδυασμός αυτών, καθώς και η χρήση βαρών. Στην συνέχεια, διαχωρίζονται τα δεδομένα σε δεδομένα εκπαίδευσης και δοκιμής με 2 διαφορετικούς τρόπους. Για την χρήση των χρονικών παραθύρων διαχωρίζονται τα δεδομένα για κάθε συμμετέχοντα ξεχωριστά, ενώ για τα παράθυρα με βάση την δραστηριότητα ο διαχωρισμός εφαρμόζεται στο σύνολο των δεδομένων. Παράλληλα, εφαρμόζονται τεχνικές εξαγωγής χαρακτηριστικών και κανονικοποίησης των δεδομένων.

Τα μοντέλα κατηγοριοποίησης που ελέγχθηκαν και αξιοποιήθηκαν είναι gradient boosting (μέσω XGBoost), K-Nearest Neighbors classifier, Convolutional Neural Networks (CNN), Artificial Neural Networks (ANN) καθώς και Long Short Term Memory (LSTM) δίκτυα. Τα αποτελέσματα που προέκυψαν για την κατηγοριοποίηση των χρονικών παραθύρων έφτασε στο 83,95% με την χρήση των LSTM δικτύων, ενώ για κάθε δραστηριότητα μέσω του XGBoost ήταν στο 82,64% (ταξινόμηση σε 3 κλάσεις). Με βάση τα περιορισμένα δεδομένα που αξιοποιήθηκαν οι ακρίβειες κρίνονται ικανοποιητικές και τα συγκεκριμένα μοντέλα θα μπορούσαν να παρέχουν επικουρική και συμβουλευτική επιτήρηση στους ηλικιωμένους.



# ABSTRACT

This thesis aims to review the Frail Safe program by bringing together all the research and work they have done on it. At the same time, an effort is being made to implement new methods, which differ from the existing ones mainly in terms of the measurements and the data used, but also some classification models.

As part of the thesis, an application was implemented in Python, which includes the appropriate interface for performing different data processing methods and categorizing time window or activity data into 3 ("Non-Frail", "Pre-Frail", "Frail") or 2 classes ("Non-Frail", "Frail"), based on the frailty index of the participant.

The data exploited is limited to only motion and behavioral data that can be extracted from a "smart" watch or phone. This aims to derive vulnerability categorization methods using easy-to-use devices. To deal with the problem of unbalanced data, the techniques SMOTE, Tomek links, a combination of them, as well as the use of weights are tested. Then, the data is separated into training and test data in 2 different ways. For the use of time windows, the data is separated for each participant separately, while for the windows based on the activity, the separation is applied to the whole data. At the same time, feature extraction and data normalization techniques are applied.

The classification models tested and utilized are gradient boosting (via XGBoost), K-Nearest Neighbors classifier, Convolutional Neural Networks (CNN), Artificial Neural Networks (ANN) as well as Long Short Term Memory (LSTM) networks. The results obtained for the categorization of time windows reached 83.95% using LSTM networks, while for each activity through XGBoost it was 82.64% (3 classes). Based on the limited data used, the accuracies are considered satisfactory and the specific models could provide adjunctive and advisory surveillance to the elderly.



# ΠΕΡΙΕΧΟΜΕΝΑ

<b>ΠΕΡΙΛΗΨΗ.....</b>	<b>3</b>
<b>ABSTRACT .....</b>	<b>5</b>
<b>ΚΑΤΑΛΟΓΟΣ ΠΙΝΑΚΩΝ .....</b>	<b>10</b>
<b>ΚΑΤΑΛΟΓΟΣ ΕΙΚΟΝΩΝ.....</b>	<b>12</b>
<b>ΚΕΦΑΛΑΙΟ 1 .....</b>	<b>14</b>
<b>ΕΙΣΑΓΩΓΗ .....</b>	<b>14</b>
1.1 Σκοπός της εργασίας .....	14
1.2 Το project FrailSafe.....	15
1.2.1 Συσκευές και αισθητήρες στο FrailSafe .....	15
1.2.2 Συμμετέχοντες στο FrailSafe .....	16
1.2.3 Ανάλυση δεδομένων και εξαγωγή μεθόδων στο FrailSafe.....	16
1.2.4 Μελέτες και εργασίες στο FrailSafe .....	17
<b>ΚΕΦΑΛΑΙΟ 2 .....</b>	<b>34</b>
<b>ΜΕΘΟΔΟΛΟΓΙΑ .....</b>	<b>34</b>
2.1 Προεπεξεργασία μη ισορροπημένων δεδομένων .....	34
2.1.1 Synthetic Minority Over-sampling Technique (SMOTE).....	34
2.1.2 Nearmiss .....	35
2.1.3 Tomek Links .....	35
2.1.4 Συνδιασμός SMOTE και Tomek Links.....	35
2.2 Αξιολόγηση αποτελεσμάτων σε μη ισορροπημένα δεδομένα .....	36
2.3 Χαρακτηριστικά χρονοσειρών .....	36
2.3.1 Εξαγωγή χαρακτηριστικών .....	36
2.3.2 Επιλογή χαρακτηριστικών .....	37
2.4 Κανονικοποίηση δεδομένων .....	38
2.5 Κατηγοριοποίηση δεδομένων .....	38
2.5.1 K-Nearest Neighbors (k-NN).....	39
2.5.2 Support Vector Machines (SVM).....	39
2.5.3 Gradient boosting.....	40
2.6 Κατηγοριοποίηση δεδομένων με χρήση νευρωνικών δικτύων .....	40
2.6.1 Λειτουργία τεχνητού νευρώνα .....	41
2.6.2 Συνάρτηση μεταφοράς .....	41
2.6.3 Κατηγορίες νευρωνικών δικτύων.....	42
2.6.4 Εκπαίδευση νευρωνικών δικτύων .....	42
2.6.5 Convolutional Neural Network (CNN).....	43
2.6.6 Long-Short Term Memory (LSTM) network.....	44

<b>ΚΕΦΑΛΑΙΟ 3</b>	46
<b>ΕΦΑΡΜΟΓΗ ΕΞΑΓΩΓΗΣ ΧΑΡΑΚΤΗΡΙΣΤΙΚΩΝ ΚΑΙ ΚΑΤΗΓΟΡΙΟΠΟΙΗΣΗΣ</b>	46
3.1 Αρχιτεκτονική	46
3.2 Η εξαγωγή χαρακτηριστικών	48
3.3 Η διεπαφή εκτέλεσης της προεπεξεργασίας δεδομένων και των μοντέλων κατηγοριοποίησης	50
3.4 Η προεπεξεργασία δεδομένων	51
3.4.1 Αντιμετώπιση μη έγκυρων τιμών	51
3.4.2 Κανονικοποίηση δεδομένων	51
3.4.2 Επιλογή χαρακτηριστικών	51
3.4.3 Αντιμετώπιση μη ισορροπημένων δεδομένων	52
3.5 Τα μοντέλα κατηγοριοποίησης	52
3.5.1 Support-Vector Machines (SVM)	52
3.5.2 Feed-Forward Neural Network (FNN)	53
3.5.3 K-Nearest Neighbors (k-NN)	53
3.5.4 Gradient boosting	54
3.5.5 Convolutional Neural Network (CNN)	54
3.5.6 Long-Short Term Memory (LSTM) network	55
3.5.7 Εύρεση βέλτιστων παραμέτρων νευρωνικών δικτύων	56
3.6 Μέγεθος παραθύρου χρονοσειρών	56
<b>ΚΕΦΑΛΑΙΟ 4</b>	58
<b>ΑΠΟΤΕΛΕΣΜΑΤΑ</b>	58
4.1 Τα δεδομένα που χρησιμοποιήθηκαν	58
4.2 Χρήση τμημάτων με βάση την πάροδο του χρόνου	58
4.2.1 Χρήση χαρακτηριστικών ανά 1 λεπτό	59
4.2.2 Αναγωγή σε πρόβλημα 2 κλάσεων	61
4.3 Χρήση τμημάτων με βάση την δραστηριότητα	64
4.3.2 Αναγωγή σε πρόβλημα 2 κλάσεων	66
<b>ΚΕΦΑΛΑΙΟ 5</b>	70
<b>ΣΥΜΠΕΡΑΣΜΑΤΑ ΚΑΙ ΜΕΛΛΟΝΤΙΚΕΣ ΕΠΕΚΤΑΣΕΙΣ</b>	70
5.1 Συμπεράσματα	70
5.2 Μελλοντικές επεκτάσεις	71
<b>ΒΙΒΛΙΟΓΡΑΦΙΑ</b>	72





## ΚΑΤΑΛΟΓΟΣ ΠΙΝΑΚΩΝ

Πίνακας 1. Εργασίες για κατηγοριοποίηση 3 κλάσεων .....	19
Πίνακας 2. Εργασίες για κατηγοριοποίηση 2 κλάσεων .....	21
Πίνακας 3. Εργασίες για πρόβλεψη δυσμενών γεγονότων .....	25
Πίνακας 4. Εργασίες για συσταδοποίηση των συμμετεχόντων (clusters = 3) .....	26
Πίνακας 5. Εργασίες για συσταδοποίηση των συμμετεχόντων (clusters = 2) .....	27
Πίνακας 6. Εργασίες για συσταδοποίηση των συμμετεχόντων (clusters = 2) .....	28
Πίνακας 7. Εργασίες για διάγνωση καρκίνου του στήθους .....	29
Πίνακας 8. Εργασίες για ανίχνευση παροξυντικού γεγονότος.....	29
Πίνακας 9. Εργασίες για ανίχνευση πτώσης.....	32
Πίνακας 10. Αποτελέσματα για τμήματα χρόνου 1 λεπτού - Χωρίς επιλογή χαρακτηριστικών .....	60
Πίνακας 11. Αποτελέσματα για τμήματα χρόνου 1 λεπτού - Με επιλογή χαρακτηριστικών (SelectPercentile 95%).....	61
Πίνακας 12. Αποτελέσματα για τμήματα χρόνου 1 λεπτού - Χωρίς επιλογή χαρακτηριστικών (2 κλάσεις) .....	62
Πίνακας 13. Αποτελέσματα για τμήματα χρόνου 1 λεπτού - Με επιλογή χαρακτηριστικών (SelectPercentile 95%) (2 κλάσεις).....	63
Πίνακας 14 Αποτελέσματα για τμήματα ανά δραστηριότητα - Χωρίς επιλογή χαρακτηριστικών (3 κλάσεις) .....	65
Πίνακας 15 Αποτελέσματα για τμήματα ανά δραστηριότητα - Με επιλογή χαρακτηριστικών (SelectPercentile 95%) (3 κλάσεις).....	66
Πίνακας 16. Αποτελέσματα για τμήματα ανά δραστηριότητα - Χωρίς επιλογή χαρακτηριστικών (2 κλάσεις) .....	67
Πίνακας 17. Αποτελέσματα για τμήματα ανά δραστηριότητα - Με επιλογή χαρακτηριστικών (SelectPercentile 95%) (2 κλάσεις).....	68



# ΚΑΤΑΛΟΓΟΣ ΕΙΚΟΝΩΝ

Εικόνα 1. SMOTE.....	34
Εικόνα 2. Tomek Links.....	35
Εικόνα 3. Δομή Τεχνητού Νευρώνα.....	41
Εικόνα 4. Το LSTM κύτταρο .....	44
Εικόνα 5. Στιγμιότυπο από την εφαρμογή.....	47
Εικόνα 6. Στιγμιότυπο από την ArangoDB.....	48
Εικόνα 7. Η διεπαφή της extract_features_from_dataset.....	49
Εικόνα 8. Η διεπαφή της train_model_via_features .....	50



# ΚΕΦΑΛΑΙΟ 1

## ΕΙΣΑΓΩΓΗ

Η αύξηση της μέσης ηλικίας και η γήρανση του πληθυσμού αποτελούν μία από τις σημαντικότερες δημογραφικές τάσεις παγκοσμίως. Η αύξηση του προσδόκιμου ζωής και οι βελτιωμένες συνθήκες διαβίωσης έχουν ως αποτέλεσμα οι πληθυσμοί να γερνούν και να αυξάνονται οι ανάγκες για υγειονομική φροντίδα και υποστήριξη των ηλικιωμένων ατόμων. Οι άνθρωποι αυτοί αντιμετωπίζουν συχνά προβλήματα υγείας, ασθένειες και απώλεια λειτουργικότητας, καθώς επίσης και αυξημένο κίνδυνο για ατυχήματα και πτώσεις. Συνεπώς, η πρόβλεψη και η πρόληψη δυσμενών γεγονότων είναι απαραίτητες για την προαγωγή της υγείας και της ασφάλειας των ηλικιωμένων και την βελτίωση της ποιότητας ζωής τους.

Οι παραδοσιακές μέθοδοι εκτίμησης ευθραυστότητας και πρόβλεψης δυσμενών γεγονότων συχνά είναι περιορισμένες και επικεντρώνονται σε κλινικά δεδομένα ή σε απομονωμένα μετρήσιμα χαρακτηριστικά. Ωστόσο, η όλο και αυξανόμενη πληθώρα συσκευών και τεχνολογιών που συλλέγουν και συγκεντρώνουν δεδομένα κίνησης και συμπεριφοράς δημιουργούν νέες προοπτικές για ακριβέστερα μοντέλα πρόβλεψης. Το σημαντικότερο όμως είναι ότι με την χρήση κάποιων από αυτών των συσκευών (smartphone, smartwatch) γίνεται όλο και πιο εφικτή η υλοποίηση χρηστικών και λειτουργικών μοντέλων, δηλαδή μοντέλων τα οποία δεν βασίζονται σε μεθόδους λήψεων δεδομένων τα οποία παρεμβαίνουν στην καθημερινότητα του χρήστη.

Η ανάπτυξη τέτοιων μοντέλων αρχικά θα βοηθήσει τους ίδιους τους ηλικιωμένους, καθώς θα είναι σε θέση να παρακολουθούν συνεχώς την υγεία τους και να προειδοποιούνται για τυχόν επιβαρύνσεις της υγείας τους έτσι ώστε να προλαμβάνουν ενδεχόμενες πτώσεις ή ατυχήματα. Παράλληλα όμως, θα αποτελέσει ένα ακόμα πολύτιμο εργαλείο στα χέρια γιατρών και ειδικών διευκολύνοντας τους στην διάγνωση και στην συστηματική παρακολούθηση των ασθενών τους. Με τον τρόπο αυτό θα είναι σε θέση να παρέχουν καλύτερα αποτελέσματα σε αυξημένη ομάδα ασθενών, προσφέροντας έτσι μια λύση στο πρόβλημα της όλο και αυξανόμενης γήρανσης του πληθυσμού που ταλανίζει τα σύγχρονα συστήματα υγείας.

### 1.1 Σκοπός της εργασίας

Σκοπός της παρούσας εργασίας είναι η συγκέντρωση όλων των εργασιών που έχουν πραγματοποιηθεί για το πρόγραμμα Frailsafe, καθώς και να αξιοποιήσει αποτελεσματικά μεθόδους προεπεξεργασίας δεδομένων και μηχανικής μάθησης έτσι ώστε να εισαχθεί ένα νέο μοντέλο κατηγοριοποίησης όσον αφορά τον δείκτη ευπάθειας των ασθενών.

Όσον αφορά το project Frailsafe, πραγματοποιήθηκαν και συνεχίζουν να πραγματοποιούνται εκτεταμένες έρευνες και εργασίες. Οι διάφορες μέθοδοι και τα αποτελέσματά τους συμπεκνώνονται στην ενότητα 1.2.3.

Στην συγκεκριμένη εργασία, μετά την ανασκόπηση των ήδη υπαρχόντων εργασιών διαπιστώθηκε η ανάγκη δοκιμής μοντέλων που θα βασίζονται σε μετρήσεις που μπορούν να εξαχθούν με καθημερινά και φθηνά μέσα για κάθε ασθενή. Για τον λόγο αυτό, τα μοντέλα κατηγοριοποίησης που θα δοκιμαστούν περιέχουν δεδομένα μόνο τέτοια που μπορούν να εξαχθούν από ένα «έξυπνο» κινητό ή ρολόι. Περιορίζοντας τα διαθέσιμα δεδομένα όμως η επίτευξη μεγάλης ακρίβειας καθίσταται δυσκολότερη σε σχέση με τις περισσότερες προηγούμενες εργασίες. Με τον τρόπο αυτό, η εργασία

αυτή επιδιώκει να προσφέρει σημαντικές συστάσεις και ευρήματα που θα ενισχύσουν την έρευνα και την ανάπτυξη στον τομέα της υγείας και της πρόβλεψης της ευπάθειας των ασθενών με χρήση τεχνολογικών μέσων. Αυτό θα συμβάλει στη βελτίωση της ποιότητας της φροντίδας των ασθενών και ηλικιωμένων και στη μείωση των υγειονομικών δαπανών.

## 1.2 To project FrailSafe

Το FrailSafe είναι ένα project που ξεκίνησε το 2016 με συμμετέχοντες από 3 κλινικά κέντρα (Ελλάδα, Κύπρος, Γαλλία). Σκοπός της έρευνας αυτής είναι κυρίως η εξαγωγή μεθόδων για την ποσοτικοποίηση ενός δείκτη ευπάθειας, η πρόβλεψη δυσμενών γεγονότων και η εκτίμηση της ευπάθειας μέσω δεδομένων που συλλέχθηκαν από συγκεκριμένες συσκευές.

### 1.2.1 Συσκευές και αισθητήρες στο FrailSafe

Συγκεκριμένα, οι συσκευές και οι αισθητήρες που κυρίως χρησιμοποιήθηκαν είναι οι παρακάτω:

1. WWBS (Wearable WBan System). Είναι μια νέα φορητή συσκευή που προέρχεται από ένα ήδη αναπτυγμένο προϊόν της Smartex, το WWS, με την περαιτέρω ενσωμάτωση κάποιων Μονάδων Αδρανειακής Μέτρησης (IMU) προκειμένου να παρέχει πληροφορίες υψηλότερης ποιότητας όσον αφορά την ανάλυση κίνησης. Αξιοποιείται κυρίως για να παρέχει δεδομένα ηλεκτροκαρδιογραφήματος (ecg), καρδιακού ρυθμού, σήματος και ρυθμού αναπνοής, στάση του σώματος, κατηγοριοποίησης δραστηριότητας και ανίχνευσης κινήσεων.

2. Smartphone. Αρχικά συνεισφέρουν στην μεταφορά δεδομένων σε άλλες συσκευές. Επίσης σε συνδυασμό με Tablet αξιοποιούνται στην εισαγωγή δεδομένων μέσω μιας πλατφόρμας παιχνιδιού αλλά και δίνοντας την δυνατότητα για άμεσα και εύχρηστα ψηφιακά ερωτηματολόγια. Παράλληλα, χάρη σε αισθητήρες (επιταχυνσιόμετρο, γυροσκόπιο, πυξίδα, μαγνητόμετρο κλπ.) που διαθέτουν τα περισσότερα σύγχρονα smartphones παρέχουν επιπλέον πληροφορίες με αρκετά καλή ακρίβεια.

3. Beacons. Για την εσωτερική παρακολούθηση των ηλικιωμένων ατόμων χρησιμοποιήθηκαν τα Bluetooth beacons. Αυτά, εκπέμπουν ένα μοναδικό αναγνωριστικό μέσω της τεχνολογίας Bluetooth Low Energy (BLE) και μπορούν να εκτιμήσουν την απόσταση της συσκευής. Με την τοποθέτηση πολλών beacons σε μια περιοχή, ένα smartphone ή tablet μπορεί να λαμβάνει ειδοποιήσεις από κάθε beacon κατά την είσοδο του σε κοντινή απόσταση. Με τον τρόπο αυτό παρέχονται πληροφορίες σχετικά με το δωμάτιο αλλά και την ακριβή θέση που βρίσκεται ο συμμετέχων.

Παράλληλα, χρησιμοποιήθηκαν συσκευές για δυναμόμετρο, την μέτρηση του βάρους, της αρτηριακής πίεσης και των παλμικών κυμάτων.

### 1.2.2 Συμμετέχοντες στο FrailSafe

Το project Frailsafe έλαβε χώρα σε 3 χώρες, Ελλάδα , Γαλλία και Κύπρο. Για τους σκοπούς αυτού, οι συμμετέχοντες χωρίστηκαν σε 4 groups:

1. Group A. Περιέχει 240 συμμετέχοντες και ονομάζεται επίσης και start group. Αυτό όπως και το Group B αξιοποιείται στο σχεδιασμό και στις δοκιμές και παρέχει ανάδραση στο αναπτυσσόμενο σύστημα.
2. Group B. Περιέχει 120 συμμετέχοντες και ονομάζεται Main Group.
3. Group C. Περιέχει 75 συμμετέχοντες και χωρίζεται και αυτό με την σειρά του σε Ci και Cii. Το Ci περιλαμβάνει τους 60 και το Cii τους 15. Αναλαμβάνουν την δοκιμή και την αξιολόγηση του συστήματος FrailSafe. Οι συμμετέχοντες εδώ λαμβάνουν εξατομικευμένες παρεμβάσεις με βάση τις μετρήσεις τους. Στρογγυλοποιώντας, το 70% ανήκει στην κατηγορία Non-Frail, το 26% στην Non-Frail και το 4% στην Frail. Το 52% είναι άντρες, ενώ το 48% είναι γυναίκες. Το Ci ονομάζεται Standard evaluation Group και το Cii Long-term evaluation Group.
4. Group D. Περιλαμβάνει 75 συμμετέχοντες. Σε αυτό υπάρχει παρακολούθηση από το FrailSafe σύστημα, χωρίς παρέμβαση. Το 60% ανήκει στην κατηγορία Non-Frail, το 24% στην κατηγορία Pre-Frail και το 8% στην Frail. Επίσης το 44% είναι άντρες, ενώ το 56% γυναίκες.

### 1.2.3 Ανάλυση δεδομένων και εξαγωγή μεθόδων στο FrailSafe

Τα δεδομένα που συλλέχθηκαν από τους συμμετέχοντες χρησιμοποιήθηκαν κυρίως για την εξαγωγή μεθόδων και τεχνικών για την εκτίμηση της ευπάθειας καθώς και την πρόβλεψη για ενδεχόμενο ατύχημα ή δυσμενές γεγονός. Οι κυριότερες μέθοδοι που αναπτύχθηκαν είναι οι εξής:

1. Κατηγοριοποίηση συμμετεχόντων με βάση την ευπάθεια τους (Frail classification), στην οποία οι συμμετέχοντες με την χρήση διαφόρων μεθόδων διαχωρίζονται σε 3 (frail, pre-frail, non-frail) ή 2 κλάσεις (frail, non-frail).
2. Συσταδοποίηση συμμετεχόντων με βάση την ευπάθεια τους (Frail clustering), κατά την οποία αξιοποιούνται τεχνικές συσταδοποίησης για τον χωρισμό τους σε διάφορους αριθμούς συστάδων.
3. Πρόβλεψη για δυσμενές γεγονός (adverse event) ή πτώση στο άμεσο μέλλον.

Επιπλέον ειδικοί μέθοδοι αναπτύχθηκαν είτε για μικρότερο αριθμό συμμετεχόντων, είτε για να αποτελέσουν εργαλεία για την βελτιστοποίηση των παραπάνω. Τέτοιοι είναι:

1. Ανίχνευση για παροξυσμικό συμβάν (Paroxysmal event).
2. Ανίχνευση της ανθρώπινης δραστηριότητας.
3. Indoor localization system.
4. Κατηγοριοποίηση με βάση αν υπάρχει καρκίνος του μαστού ή όχι.



### 1.2.4 Μελέτες και εργασίες στο FrailSafe

Κατά την υλοποίηση του project αναπτύχθηκαν και συνεχίζουν να αναπτύσσονται αρκετές μελέτες και εργασίες. Στην παρούσα διπλωματική εργασία γίνεται μία ανασκόπηση όλων αυτών των εργασιών, των μεθόδων καθώς και των αποτελεσμάτων που προέκυψαν σχετικά με αυτό μέχρι την δεδομένη χρονική στιγμή. Οι παρακάτω πίνακες αποτελούν σύνοψη όλων των μεθόδων και των αποτελεσμάτων που προέκυψαν. Κάθε τιμή της πρώτης στήλης αντιστοιχεί σε εργασία όπως αναφέρονται στη βιβλιογραφία. Η δεύτερη στήλη αναφέρεται στην πηγή των δεδομένων τα οποία χρησιμοποιήθηκαν και η τρίτη στα χαρακτηριστικά (features) που εξάχθηκαν, καθώς και στον αλγόριθμο με τον οποίο έγινε η εξαγωγή ή και η επιλογή (αν χρησιμοποιήθηκε). Η τέταρτη αντιστοιχεί στην ακρίβεια στην οποία προέκυψε το αντίστοιχο μοντέλο το οποίο αναφέρεται στην πέμπτη στήλη.

**Κατηγοριοποίηση σε 3 Κλάσεις (Frail, Pre-Frail, Non-Frail)**

Thesis/ Paper	Data	Features	Accuracy	Model
[1] Accelerometers, Ecg		standard deviation, mean, root mean square, mean absolute deviation, mode, entropy, prctile(95), prctile(5)	70%	CNN
[2] Daily Files/Temperature		id, temperature, max distance, mean distance, mean duration, mean speed, max speed, mean area, fall or not (Per Day)	46%	KNN
[2] Daily Files/Temperature		"same as above"	62%	Decision Tree
[2] Daily Files/Temperature		"same as above"	62%	Decision Tree
[2] Daily Files/Temperature		"same as above"	59%	Radom Forest
[2] Daily Files/Temperature		"same as above"	41%	SVM
[6] Beacons		via Feature Extraction for Moving Window Segments feature selection: None	94,45%	KNN
[6] Beacons		via Feature Extraction for Moving Window Segments feature selection: None	90,52%	C-SVM
[6] Beacons		via Feature Extraction for Moving Window Segments feature selection: None	89,5%	Radom Forest

[6]	Beacons	feature selection: None	56,58%	ANN
[6]	Beacons	via Feature Extraction for Moving Window Segments feature selection: chi2 ( $x^2$ )	66,03%	Decision Tree
[6]	Beacons	via Feature Extraction for Moving Window Segments feature selection: PCA (Principal Component Analysis)	48,48%	Naive Bayes
[7]	WWBS/Games/ GPS/ Clinical	*Features1	56%-94%	SPEC-MIL
[7]	WWBS/Games/GPS/ Clinical	*Features1	49%-90%	MILES
[7]	WWBS/Games/GPS/ Clinical	*Features1	55%-91%	MI-ELM
[7]	WWBS/Games/GPS/ Clinical	*Features1	55%-83%	Fusion of 3 classifiers
[10]	Beacons	*Features2	82,33%	Random Forest
[10]	Beacons	*Features2	71,78%	Decision Trees
[10]	Beacons	*Features2	55,11%	Neural Network
[10]	Beacons	*Features2	57,01%	KNN (K=10)
[10]	Beacons	*Features2	27,65%	Naive Bayes
[11]	Ecg	Feature extraction was performed using the ALS algorithm from full data and the StrProxSGD algorithm for missing data	73,41%	TensMIL
[12]	Beacons	*Features2	59,06%	Random Forest
[12]	Beacons	*Features2	54,69%	Decision Trees
[12]	Beacons	*Features2	50%	Neural Network
[12]	Beacons	*Features2	48,82%	KNN (K=10)
[12]	Beacons	*Features2	47,64%	Naive Bayes

[27]	Beacons	*Features2	-	Random Forest
------	---------	------------	---	---------------

Πίνακας 1. Εργασίες για κατηγοριοποίηση 3 κλάσεων

**\*Features1 :**

via ReliefF–MI (extension fo ReliefF)

**WWBS:**

Acceleration, Respiration Rate, Breathing Rate, Heart Rate, Heart Rate Variability, R-R interval in EGG

**Games:**

Max Force, Average max force, Average endurance, Max endurance, Average score, Max game duration, Height over game duration, Speed over game duration, Speed over game duration, Force over game duration

**GPS:**

total distance, total duration, total number of steps, radius covered, area covered, total walk time, total stop time, total vehicle time, walk time percentage, vehicle time percentage, stop time percentage, track number, track average distance, track average duration, track maximum distance, track maximum duration

**\*Features2 :**

1. Number of room transitions
2. Room transition average time duration
3. Room transition standard deviation of time duration
4. Number of fast room transitions
5. Number of slow room transitions
6. Percentage of fast room transitions
7. Percentage of slow room transitions
8. Normalized number of fast room transitions
9. Normalized number of slow room transitions

Στον πίνακα 2, υπάρχουν όλες οι ερευνητικές εργασίες που εμπεριείχαν μοντέλα κατηγοριοποίησης σε 2 κλάσεις. Ο περιορισμός σε 2 κλάσεις μπορεί να οδηγήσει σε μεγαλύτερη ακρίβεια κατηγοριοποίησης. Υστερεί όμως στην δυνατότητα να διαχωρίζει ορθότερα τους ηλικιωμένους σε σχέση με την κλινική τους εικόνα.

### Κατηγοριοποίηση σε 2 Κλάσεις (Frail, Non-Frail)

Thesis/P aper	Data	Features	Accuracy	Model
[27]	Beacons	*Features2	94% (balanced)	Random Forest
[2]	Daily Files/ Temperature	id, temperature, max distance, mean distance, mean duration, mean speed, max speed, mean area, fall or not (Per Day)	63%	KNN
[2]	Daily Files/ Temperature	"same as above"	86%	Decision Trees
[2]	Daily Files/ Temperature	"same as above"	68%	Naive Bayes
[2]	Daily Files/ Temperature	"same as above"	81%	Random Forest
[2]	Daily Files/ Temperature	"same as above"	70%	SVM
[3]	Beacons	*Features3	88%	Naive Bayes
[3]	Beacons	*Features3	95%	KNN (k=5)
[3]	Beacons	*Features3	79%	Neural Network
[3]	Beacons	*Features3	95%	Decision Tree
[3]	Beacons	*Features3	94%	Random Forest
[3]	Beacons	*Features3	95%	Bagging Classifier
[3]	Beacons	*Features3	94%	Extra Trees Classifier
[3]	Beacons	*Features3	92%	AdaBoost Classifier
[3]	Beacons	*Features3	91%	Gradient Boosting
[3]	Beacons	*Features3	95%	Voting Classifier
[3]	Beacons	*Features3	55%	XGBoost
[3]	Beacons	*Features3	55%	Decision Tree based on Forest
[6]	Beacons	via Feature Extraction for Moving Window Segments feature selection: None	94,73%	KNN

[6]	Beacons	via Feature Extraction for Moving Window Segments feature selection: None	91,62%	C-SVM
[6]	Beacons	via Feature Extraction for Moving Window Segments feature selection: None	91,64%	Random Forest
[6]	Beacons	feature selection: None	62,92%	ANN
[6]	Beacons	via Feature Extraction for Moving Window Segments feature selection: Ida (Linear Discriminant Analysis)	64,36%	Naive Bayes
[11]	Ecg	Feature extraction was performed using the ALS algorithm from full data and the StrProxSGD algorithm for missing data	80,83%	TensMIL
[12]	Beacons	*Features2	73,13%	Random Forest
[12]	Beacons	*Features2	76,88%	Decision Trees
[12]	Beacons	*Features2	79,38%	Neural Network
[12]	Beacons	*Features2	82,5%	KNN (K=10)
[12]	Beacons	*Features2	77,5%	Naive Bayes

Πίνακας 2. Εργασίες για κατηγοριοποίηση 2 κλάσεων

**\*Features3 :**

1. Number of room transitions
2. Room transition average time duration
3. Room transition standard deviation of time duration
4. Number of fast room transitions,
5. Number of slow room transitions,
6. Number of slow room transitions,
7. Percentage of slow room transitions,
8. Rate of stay in each room,
9. Id of room with most transitions,
10. Number of transitions per hour,
11. Number of rooms in current season,
12. Time of current season,
13. Day or night,
14. Number of transitions at night,
15. Room where there was a longer stay,
16. Number of consecutive fast transitions

Τα δυσμενές γεγονότα περιλαμβάνουν γεγονότα πτώσεων, καταγμάτων, εισαγωγών στο νοσοκομείο και, τέλος, θανάτου. Συνήθως συμβαίνουν μετά από μια αλλαγή στον δείκτη ευπάθειας από Non-Frail προς την κατηγορία Frail. Επομένως η έγκαιρη πρόβλεψη τέτοιων καταστάσεων εξαρτάται σε μεγάλο βαθμό από την σωστή πρόβλεψη του δείκτη ευπάθειας. Είναι ιδιαίτερα σημαντικό να προβλεφθούν, έτσι ώστε να αποφευχθούν. Για τους λόγους αυτούς πραγματοποιήθηκαν αρκετές εργασίες και έρευνα οι οποίες συμπυκνώνονται στον Πίνακα 3.

### Πρόβλεψη για δυσμενές γεγονός (adverse event) ή πτώση

Thesis/ Paper	Data	Features	Accuracy	Model
[2]	Daily Files/Temperature	id, temperature ,max distance, mean distance, mean duration, mean speed, max speed,mean area, fall or not (Per Day)	76%	KNN
[2]	Daily Files/Temperature	"same as above"	75%	Decision Tree
[2]	Daily Files/Temperature	"same as above"	57%	SVM
[3]	Beacons	*Features3	73% (53% balanced)	Naïve Bayes
[3]	Beacons	*Features3	97% (97% balanced)	KNN (k=5)
[3]	Beacons	*Features3	86% (80% balanced)	Neural Network
[3]	Beacons	*Features3	95% (72% balanced)	Decision Tree
[3]	Beacons	*Features3	97% (97% balanced)	Random Forest
[3]	Beacons	*Features3	96%	KNN (Ensemble)
[3]	Beacons	*Features3	94%	Random Forest (Ensemble)
[3]	Beacons	*Features3	95%	Logistic Regressor (Ensemble)
[3]	Beacons	*Features3	96%	Embedded Voting (Ensemble)

[6]	Beacons	Delta Frailty Index feature selection: lda (Linear Discriminant Analysis)	95,46% (82,65% balanced)	C-SVM
[6]	Beacons	Delta Frailty Index feature selection: f_clf	93,14% (85,29% balanced)	KNN
[6]	Beacons	Delta Frailty Index feature selection: f_clf	95,95% (87,06% balanced)	Naive Bayes
[6]	Beacons	Delta Frailty Index feature selection: None	95,42% (87,06% balanced)	Decision Trees
[6]	Beacons	5 days data	81,81% (82,18% balanced)	CNN - Instance Space
[26]	WWBS/Games	features accumulated over the multiple sessions for every participant, and the estimated temporal change of extracted features (slope)	68%	SVM
[27]	WWBS/Games suite/GPS/ clinical measurements/Fried frailty	temporal (raw) variables (*Features5)	69% (65% balanced)	SPEC_MIL
[27]	WWBS/Games suite/ clinical measurements/ Fried frailty	temporal (raw) variables (*Features5)	69% (65% balanced)	SPEC_MIL
[27]	Games suite/GPS/ clinical measurements/ Fried frailty	temporal (raw) variables (*Features5)	70% (65% balanced)	SPEC_MIL
[27]	WWBS/GPS/ clinical measurements/ Fried frailty	temporal (raw) variables (*Features5)	70% (64% balanced)	SPEC_MIL
[27]	WWBS/Games suite /GPS/ Fried frailty	temporal (raw) variables (*Features5)	61% (51% balanced)	SPEC_MIL
[27]	Fried frailty	temporal (raw) variables (*Features5)	-	SPEC_MIL
[27]	GPS	temporal (raw) variables (*Features5)	65% (50% balanced)	SPEC_MIL
[27]	WWBS	temporal (raw) variables (*Features5)	65% (55% balanced)	SPEC_MIL
[27]	Games suite	temporal (raw) variables (*Features5)	61% (47% balanced)	SPEC_MIL

[27]	Clinical measurements	temporal (raw) variables (*Features5)	70% (63% balanced)	SPEC_MIL
[27]	GPS/Games suite	temporal (raw) variables (*Features5)	59% (46% balanced)	SPEC_MIL
[27]	GPS/Text	temporal (raw) variables (*Features5)	65% (50% balanced)	SPEC_MIL
[27]	GPS/clinical measurements	temporal (raw) variables (*Features5)	69% (62% balanced)	SPEC_MIL
[27]	WWBS/GPS	temporal change of variables (*Features5)	65% (56% balanced)	SPEC_MIL
[27]	WWBS/Games suite	temporal change of variables (*Features5)	64% (54% balanced)	SPEC_MIL
[27]	WWBS/Text	temporal change of variables (*Features5)	65% (55% balanced)	SPEC_MIL
[27]	WWBS/Clinical	temporal change of variables (*Features5)	69% (65% balanced)	SPEC_MIL
[27]	Games suite/Text	temporal change of variables (*Features5)	61% (47% balanced)	SPEC_MIL
[27]	Games suite/Clinical measurements	temporal change of variables (*Features5)	70% (65% balanced)	SPEC_MIL
[27]	WWBS/Games suite/GPS/ clinical measurements/ Fried frailty	temporal change of variables (*Features5)	60% (57% balanced)	SPEC_MIL
[27]	WWBS/Games suite/ clinical measurements/ Fried frailty	temporal change of variables (*Features5)	69% (68% balanced)	SPEC_MIL
[27]	Games suite/GPS/ clinical measurements/ Fried frailty	temporal change of variables (*Features5)	45% (42% balanced)	SPEC_MIL
[27]	WWBS/GPS/ clinical measurements/ Fried frailty	temporal change of variables (*Features5)	58% (52% balanced)	SPEC_MIL
[27]	WWBS/Games suite/GPS/Fried frailty	temporal change of variables (*Features5)	65% (62% balanced)	SPEC_MIL
[27]	Fried frailty	temporal change of variables (*Features5)	61% (47% balanced)	SPEC_MIL
[27]	Gps	temporal change of variables (*Features5)	67% (58% balanced)	SPEC_MIL



[27]	WWBS	temporal change of variables (*Features5)	61% (55% balanced)	SPEC_MIL
[27]	Games suite	temporal change of variables (*Features5)	59% (55% balanced)	SPEC_MIL
[27]	Clinical measurements	temporal change of variables (*Features5)	47% (39% balanced)	SPEC_MIL
[27]	GPS/Games suite	temporal change of variables (*Features5)	61% (55% balanced)	SPEC_MIL
[27]	GPS/Text	temporal change of variables (*Features5)	67% (58% balanced)	SPEC_MIL
[27]	GPS/clinical measurements	temporal change of variables (*Features5)	47% (87,06% balanced)	SPEC_MIL
[27]	WWBS/GPS	temporal change of variables (*Features5)	60% (55% balanced)	SPEC_MIL
[27]	WWBS/Games suite	temporal change of variables (*Features5)	71% (69% balanced)	SPEC_MIL
[27]	WWBS/Text	temporal change of variables (*Features5)	61% (55% balanced)	SPEC_MIL
[27]	WWBS/Clinical	temporal change of variables (*Features5)	58% (54% balanced)	SPEC_MIL
[27]	Games suite/Text	temporal change of variables (*Features5)	59% (55% balanced)	SPEC_MIL
[27]	Games suite/Clinical measurements	temporal change of variables (*Features5)	45% (41% balanced)	SPEC_MIL

Πίνακας 3. Εργασίες για πρόβλεψη δυσμενών γεγονότων

**\*Features5 :**

**WWBS:**

This feature extraction process

resulted to 315 (9 statistical properties × 7 channels × 5 activities)

*statistical properties:* average, standard

deviation, 5% and 95% percentiles, mode, skewness, kurtosis, energy, entropy.

*activities:* sitting/standing, laying down, walking forward, walking upstairs or downstairs, and transition of activity

**Game platform and dynamometer:**

53 (8 variables + 9 statistical properties × 5 dynamic variables)

eight features were summarized variables exported by the game application characterizing game performance.

*dynamic measurements*: height and the speed of the plane, the distance it covered, the remaining lives of the user and the force applied over the game statistical properties: average, standard

deviation, 5% and 95% percentiles, mode, skewness, kurtosis, energy, entropy.

**GPS data**: Finally, a number of features was extracted from the GPS data collected through the outdoor monitoring application (GPS logger).

#### **Clinical Measurements:**

two types of clinical

metrics - the ones quantified in a numeric scale, such as the TUG (Timed Up and Go)

test, and the categorical ones, such as the frailty status according to Fried

#### **Συσταδοποίηση συμμετεχόντων με βάση την ευπάθεια (clusters = 3)**

Thesis/ Paper	Data	Features	Silhouette score	Model
[5]	IMU at sternum/ Games	Average, Standard deviation, 5% 95% percentiles, Mode, Skewness, Kurtosis, Energy, Entropy	77,64%	Kmeans (silhouette score) Agglomerative
[5]	Mobile GPS	Distance, Duration, Steps, Radius, walk speed, Number of tracks, walk/ top/vehicle time		
[5]	Clinical Data	Clinical features	78,06%	Kmeans(silhouette score)
[16]	WWBS/Games/GPS	distance, track average duration, track maximum distance, track maximum duration	94%	Agglomerative
[16]	WWBS/Games/GPS	"same as above"	90%	Birch
[16]	WWBS/Games/GPS	"same as above"	94%	Spectral clustering
[16]	WWBS/Games/GPS	"same as above"	94%	Kmeans
[16]	WWBS/Games/GPS	"same as above"	94%	combination of their results by majority voting
[27]	Clinical evaluation	PCA+LLE	78,06%	KMeans

Πίνακας 4. Εργασίες για συσταδοποίηση των συμμετεχόντων (clusters = 3)

**\*Features6:****WWBS:**

9 statistical properties  $\times$  7 channels  $\times$  5 activities

Acceleration, Respiration Rate, Breathing Rate, Breathing Amplitude, Heart Rate, Heart Rate Variability, R-R interval in ECG

**Game Brainstorm:**

53 (8 variables + 9 statistical properties  $\times$  5 dynamic variables).

Variables: Max force, Average max force, Average endurance, Max endurance

Average score, Max score, Average game duration, Max game duration,

Height over game duration, Distance over game duration, Speed over game duration,

Lives over game duration, Force over game duration

**GPS data:**

total distance, total duration, total number of steps, radius covered, area covered,

average walk speed, total walk time, total stop time, total vehicle time, walk time percentage,

vehicle time percentage, stop time percentage, track number, track average distance, track average duration, track maximum distance, track maximum duration.

**Συσταδοποίηση συμμετεχόντων με βάση την ευπάθεια (clusters = 2)**

Thesis/ Paper	Data	Features	Silhouette score	Model
[16]	WWBS/Games/GPS	*Features6	96%	Agglomerative
[16]	WWBS/Games/GPS	*Features6	96%	Birch
[16]	WWBS/Games/GPS	*Features6	96%	Spectral clustering
[16]	WWBS/Games/GPS	*Features6	96%	Kmeans
[16]	WWBS/Games/GPS	*Features6	96%	combination of their results by majority voting
[16]	WWBS/Games/GPS	*Features6	42%-100%	

Πίνακας 5. Εργασίες για συσταδοποίηση των συμμετεχόντων (clusters = 2)

**Ανίχνευση ανθρώπινης δραστηριότητας**

Thesis/ Paper	Data	Features	Accuracy	Model
[4]	IMUs/Smartphone	*Features7	84,89%	CNN1
[4]	IMUs/Smartphone	*Features7	98,37%	CNN3
[8]	IMU at sternum	*Features7	81,91%	CNN1

[8]	IMU at sternum	*Features7	78,49%	CNN2
[8]	IMU at sternum	*Features7	82,47%	CNN3
[8]	IMU at sternum	*Features7	81,7%	SVM
[8]	IMU at sternum	*Features7	81,7%	SVM
[25]	-	*Features8	95,84%	SVM
[26]	WWBS	based on the accelerometer	-	SVM/Deep learning techniques

Πίνακας 6. Εργασίες για συσταδοποίηση των συμμετεχόντων (clusters = 2)

#### **\*Features7 :**

1. Mean value
2. Standard deviation
3. Median absolute deviation
4. Largest value in array
5. Smallest value in array
6. Signal magnitude area
7. Energy measure
8. Interquartile range
9. Signal entropy
10. Autoregression
11. Coefficients
12. Correlation coefficient between two signals
13. Index of the frequency component with largest magnitude
14. Weighted average of the frequency components to obtain a mean frequency,
15. skewness of the frequency domain signal,
16. Kurtosis of the frequency domain signal and energy of a frequency interval within the 64 bins of the FFT of each window.

#### **\*Features8:**

ReliefF features from accelerometer and gyroscope  
best 20 features:

1. GravityAcc\_energy\_X
2. fBodyAccJerk\_entropy\_X
3. fBodyAcc\_entropy\_X
4. fBodyAccJerk\_entropy\_Y
5. tBodyAccJerkMag\_entropy
6. angle(X\_gravityMean)
7. tGravityAcc\_min\_X
8. tGravityAcc\_mean\_X
9. tBodyAccJerk\_entropy\_X

10. tGravityAcc\_max\_X
11. fBodyBodyAccJerkMag\_entropy
12. tBodyAcc\_max\_X
13. tBodyAccJerk\_entropy\_Y
14. fBodyAccMag\_entropy
15. fBodyAcc\_entropy\_Y
16. fBodyAccJerk\_entropy\_Z
17. tBodyAccJerk\_entropy\_Z
18. tBodyGyroJerkMag\_entropy
19. tGravityAcc\_energy\_Y
20. tBodyAccMag\_entropy

#### Διάγνωση καρκίνου στο στήθος

Thesis/ Paper	Data	Features	Accuracy	Model
[11]	Histopathology images	via PARAFAC mean SIFT descriptors, local binary patterns with 20 ×20-pixel cells, intensity histogram of 26 bins for each of the RGB channels, and mean feature vector of the cells lying in that patch	79,33%	TensMIL

Πίνακας 7. Εργασίες για διάγνωση καρκίνου του στήθους

#### Ανίχνευση παροξυντικού γεγονότος

Thesis/ Paper	Data	Features	Accuracy	Model
[15]	EEG	*Features9	90,24%	BayesNet
[15]	EEG	*Features9	88,78%	BayesNet
[15]	EEG	*Features9	90,24%	BayesNet
[15]	Accelerometer/ Gyroscope/ Magnetometer (Falls Dataset)	*Features10	99,76%	SVM
[15]	Accelerometer/Gyroscope/ Magnetometer (Falls Dataset)	*Features10	99,72%	SVM
[15]	Accelerometer/Gyroscope/ Magnetometer (Falls Dataset)	*Features10	98,41%	SVM

Πίνακας 8. Εργασίες για ανίχνευση παροξυντικού γεγονότος

**\*Features9:**

1. Minimum value
2. Maximum value
3. Mean
4. Variance
5. Standard deviation
6. Percentiles (25%, 50%-median and 75%)
7. Interquartile range
8. Mean absolute deviation
9. Range
10. Skewness
11. Kurtosis
12. Energy
13. Shannon's entropy
14. Logarithmic energy entropy
15. Number of positive and negative peaks
16. Zero-crossing rate
17. 6-th order autoregressive-filter (AR) coefficients
18. Power spectral density
19. Frequency with maximum and minimum amplitude
20. Spectral entropy,
21. Deltatheta-alpha-beta-gamma band energy
22. Discrete wavelet transform coefficients with mother wavelet function
23. Daubechies 16 and decomposition level equal to 8

**\*Features10:**

1. Minimum
2. Maximum
3. Mean values
4. Skewness
5. Kurtosis
6. The first 11 values of the autocorrelation sequence,
7. The first five peaks of the discrete Fourier transform of the signal with the corresponding frequencies  $26 \times 9$  (3 axes - 3D accelerometer, 3D gyroscope, and 3D magnetometer)

Thesis/ Paper	Data	Features	Accuracy	Model
[22]	Head Sensor	*Features11	96,48%	Decision Trees
[22]	Head Sensor	*Features11	93,70%	KNN
[22]	Head Sensor	*Features11	97,17%	Ensemble classifier (RC)
[22]	Head Sensor	*Features11	96,77%	Ensemble classifier (RF)
[22]	Head Sensor	*Features11	97,29%	Support Vector Machines
[22]	Chest Sensor	*Features11	97,53%	Decision Trees
[22]	Chest Sensor	*Features11	97,45%	KNN
[22]	Chest Sensor	*Features11	98,61%	Ensemble classifier (RC)
[22]	Chest Sensor	*Features11	98,61%	Ensemble classifier (RF)
[22]	Chest Sensor	*Features11	98,89%	Support Vector Machines
[22]	Waist Sensor	*Features11	97,96%	Decision Trees
[22]	Waist Sensor	*Features11	98,61%	KNN
[22]	Waist Sensor	*Features11	98,89%	Ensemble classifier (RC)
[22]	Waist Sensor	*Features11	99,28%	Ensemble classifier (RF)
[22]	Waist Sensor	*Features11	99,36%	Support Vector Machines
[22]	Wrist Sensor	*Features11	93,71%	Decision Trees
[22]	Wrist Sensor	*Features11	89,74%	KNN
[22]	Wrist Sensor	*Features11	94,63%	Ensemble classifier (RC)
[22]	Wrist Sensor	*Features11	95,62%	Ensemble classifier (RF)
[22]	Wrist Sensor	*Features11	96,78%	Support Vector Machines
[22]	Thigh Sensor	*Features11	98,24%	Decision Trees
[22]	Thigh Sensor	*Features11	96,42%	KNN
[22]	Thigh Sensor	*Features11	98,77%	Ensemble classifier (RC)
[22]	Thigh Sensor	*Features11	99,20%	Ensemble classifier (RF)
[22]	Thigh Sensor	*Features11	99,48%	Support Vector Machines
[22]	Ankle Sensor	*Features11	97,45%	Decision Trees
[22]	Ankle Sensor	*Features11	95,58%	KNN

[22]	Ankle Sensor	*Features11	98,77%	Ensemble classifier (RC)
[22]	Ankle Sensor	*Features11	98,77%	Ensemble classifier (RF)
[22]	Ankle Sensor	*Features11	98,57%	Support Vector Machines

Πίνακας 9. Εργασίες για ανίχνευση πτώσης

**\*Features11 :**

1. Minimum
2. Maximum and mean values,
3. Skewness, kurtosis
4. The first 11 values of the autocorrelation sequence
5. The first five frequencies with maximum magnitude of the DFT along with the five corresponding amplitudes





## ΚΕΦΑΛΑΙΟ 2

## ΜΕΘΟΔΟΛΟΓΙΑ

### 2.1 Προεπεξεργασία μη ισορροπημένων δεδομένων

Η προεπεξεργασία μη ισορροπημένων δεδομένων αποτελεί ένα κρίσιμο βήμα για την επίτευξη υψηλής απόδοσης στα μοντέλα μηχανικής μάθησης. Σε καταστάσεις όπου ο αριθμός των δειγμάτων κάθε κλάσης διαφέρει σημαντικά, τα εξαγόμενα μοντέλα ταξινόμησης είναι πολύ πιθανόν να παρουσιάσουν χαμηλές ακρίβειες, αν δεν εφαρμοστούν οι κατάλληλες τεχνικές.

Ένα απλό βήμα για την αντιμετώπιση του προβλήματος είναι η επιλογή σωστής μετρικής αξιολόγησης. Αντί για την ακρίβεια (accuracy), η οποία μπορεί να είναι παραπλανητική σε μη ισορροπημένα δεδομένα, η F1-score παρέχει μια πιο ισορροπημένη εικόνα της απόδοσης του μοντέλου, καθώς λαμβάνει υπόψη τόσο την ακρίβεια (precision) όσο και την ανάκληση (recall).


Επιπλέον, μια προσέγγιση είναι η χρήση τεχνικών υπερδειγματοληψίας, όπως η υπερδειγματοληψία μειονοτικών κλάσεων (oversampling) ή η υποδειγματοληψία κυρίαρχων κλάσεων (undersampling). Η υπερδειγματοληψία μπορεί να γίνει με την αντιγραφή τυχαίων δειγμάτων μειονοτικών κλάσεων ή με τη χρήση τεχνικών όπως το SMOTE (Synthetic Minority Over-sampling Technique), που δημιουργεί συνθετικά δείγματα. Η υποδειγματοληψία μπορεί να γίνεται μέσω αλγορίθμων, όπως ο NearMiss ή ο Tomek Links.

Άλλες τεχνικές είναι εφαρμογή της αποκοπής (trimming) ή της ρύθμισης των βαρών (reweighting) στα δεδομένα. Με την αποκοπή, αφαιρούμε τυχαία δείγματα από τις κυρίαρχες κλάσεις, ενώ με τη ρύθμιση, προσαρμόζουμε τα βάρη των κλάσεων έτσι ώστε να λαμβάνονται περισσότερα υπόψη οι μειονοτικές. Για να έχουμε πιο ρεαλιστικά αποτελέσματα είναι σημαντικό να εφαρμόζονται οι τεχνικές αυτές μόνο στα δεδομένες εκπαίδευσης και όχι στα δοκιμής.

#### 2.1.1 Synthetic Minority Over-sampling Technique (SMOTE)

Η SMOTE είναι μια τεχνική υπερδειγματοληψίας που χρησιμοποιείται για να δημιουργήσει συνθετικά δείγματα για τις μειονοτικές κλάσεις. Η διαδικασία γίνεται ως εξής:

Για κάθε δείγμα της μειονοτικής κλάσης, επιλέγονται τυχαία δύο κοντινά δείγματα από την ίδια κλάση. Έπειτα, δημιουργείται ένα νέο δείγμα που βρίσκεται ανάμεσα στα δύο επιλεγμένα δείγματα. Αυτό έχει ως αποτέλεσμα να αυξάνεται ο αριθμός των δειγμάτων της μειονοτικής κλάσης και να βελτιώνεται η ικανότητα του μοντέλου να ταξινομεί τις μειονοτικές κλάσεις.



Εικόνα 1. SMOTE


### 2.1.2 Nearmiss

Η τεχνική Nearmiss έχει σαν αποτέλεσμα την μείωση του αριθμού των δειγμάτων της πλειονοτικής κλάσης, κάνοντας τις κλάσεις πιο ισορροπημένες. Ωστόσο, η τεχνική Nearmiss μπορεί να οδηγήσει επίσης σε απώλεια πληροφορίας από την πλειονοτική κλάση, ειδικά αν τα δείγματα της πλειονοτικής κλάσης έχουν σημασιολογικά και δομικά χαρακτηριστικά που είναι σημαντικά για τον ταξινομητή.

Συγκεκριμένα, η τεχνική Nearmiss εφαρμόζει την αφαίρεση δειγμάτων από την πλειονοτική κλάση, κρατώντας τα πιο κοντινά δείγματα (με βάση την ευκλείδεια απόσταση) προς την μειονοτική κλάση.

### 2.1.3 Tomek Links

Η Tomek Links είναι μια άλλη τεχνική προεπεξεργασίας που στοχεύει στην επιβολή της απόστασης μεταξύ των δύο κλάσεων. Αυτή η μέθοδος βασίζεται στην αφαίρεση των Tomek Links, που είναι ζεύγη δειγμάτων που ανήκουν σε διαφορετικές κλάσεις και βρίσκονται πολύ κοντά ο ένας στον άλλον στο χώρο των χαρακτηριστικών. Αυτό το καθαριστικό βήμα μπορεί να αυξήσει την απόδοση του μοντέλου, καθώς δημιουργεί μεγαλύτερο ξεχωριστό χώρο μεταξύ των δύο κλάσεων.



Εικόνα 2. Tomek Links

### 2.1.4 Συνδυασμός SMOTE και Tomek Links

Ο συνδυασμός των μεθόδων SMOTE (Synthetic Minority Over-sampling Technique) και Tomek Links αποτελεί μια ισχυρή στρατηγική για την αντιμετώπιση προβλημάτων ανισορροπίας κατηγοριών σε σύνολα δεδομένων. Και οι δύο τεχνικές στοχεύουν στη βελτίωση της απόδοσης του μοντέλου πρόβλεψης όταν έχουμε μικρό αριθμό παραδειγμάτων σε μία κατηγορία σε σχέση με την άλλη. Η τεχνική SMOTE βοηθά στην αύξηση του αριθμού των δειγμάτων της ελάχιστης κατηγορίας, ενώ η Tomek Links συνεισφέρει στον καλύτερο διαχωρισμό μεταξύ των δύο κατηγοριών, μειώνοντας την πιθανότητα παραβολής μεταξύ τους. Αυτός ο συνδυασμός συχνά έχει ως αποτέλεσμα ένα πιο ακριβές και αξιόπιστο μοντέλο πρόβλεψης.

## 2.2 Αξιολόγηση αποτελεσμάτων σε μη ισορροπημένα δεδομένα

Η αξιολόγηση των αποτελεσμάτων σε μη ισορροπημένα δεδομένα είναι κρίσιμη για την κατανόηση της απόδοσης ενός μοντέλου μηχανικής μάθησης. Τα παρακάτω μετρικά είναι απαραίτητα για μία ολοκληρωμένη εικόνα για την απόδοση του μοντέλου:

1. Accuracy (Ακρίβεια): Η ακρίβεια αποτελεί μια βασική μετρική που μετρά το ποσοστό των σωστών προβλέψεων συνολικά. Είναι το ποσοστό των σωστών προβλέψεων (True Positives και True Negatives) προς τον συνολικό αριθμό παραδειγμάτων.
2. Η precision (ή θετική προβλεπτική αξία) αναφέρεται στο ποσοστό των πραγματικών θετικών προβλέψεων (True Positives) ανάμεσα στις θετικές προβλέψεις (True Positives και False Positives). Δηλαδή, πόσες από τις προβλέψεις για θετικές ετικέτες είναι πραγματικά σωστές.
3. Recall (Ανάκληση). Η recall (ή ευαισθησία) μετρά το ποσοστό των πραγματικών θετικών προβλέψεων (True Positives) ανάμεσα στις πραγματικές θετικές ετικέτες (True Positives και False Negatives). Αυτό δείχνει πόσα από τα πραγματικά θετικά παραδείγματα εντοπίστηκαν από το μοντέλο.
4. F-score (F-μέτρο). Το F-score είναι ένας συνδυασμός της precision και της recall, που βοηθά να εξισορροπηθούν οι δύο μετρικές. Είναι ένας τρόπος να αξιολογηθεί η συνολική απόδοση του μοντέλου, λαμβάνοντας υπόψη και τα false positives και false negatives.

$$\text{precision} = \frac{tp}{tp + fp}$$

$$\text{recall} = \frac{tp}{tp + fn}$$

$$\text{accuracy} = \frac{tp + tn}{tp + fp + tn + fn}$$

$$F - \text{measure} = \frac{2 * \text{precision} * \text{recall}}{\text{precision} + \text{recall}}$$

## 2.3 Χαρακτηριστικά χρονοσειρών

### 2.3.1 Εξαγωγή χαρακτηριστικών

Η εξαγωγή χαρακτηριστικών σε χρονοσειρές αποτελεί μια απαραίτητη διαδικασία για την ανάλυση και την κατανόηση των χρονοσειριακών δεδομένων. Καθώς οι χρονοσειρές αποτελούνται από συνεχόμενες μετρήσεις που παρατηρούνται σε διαφορετικά χρονικά σημεία, η εξαγωγή σημαντικών χαρακτηριστικών είναι ουσιώδης για την αποτελεσματική ανάλυση και πρόβλεψη των μοτίβων και των τάσεων που περιέχονται σε αυτές.

Η κατηγοριοποίηση δεδομένων σε κλάσεις αποτελεί ένα κρίσιμο πρόβλημα στην περιοχή της μηχανικής μάθησης και της αναγνώρισης προτύπων. Μια σημαντική πτυχή αυτού του προβλήματος είναι η εξαγωγή χαρακτηριστικών από χρονοσειρές, καθώς οι χρονοσειρές αποτελούν συνήθως πολύπλοκα δεδομένα με πληθώρα πληροφορίας. Η κατάλληλη εξαγωγή χαρακτηριστικών μπορεί να

βοηθήσει στην κατηγοριοποίηση και αναγνώριση μοτίβων σε αυτές τις χρονοσειρές.

Η προσέγγιση για την εξαγωγή χαρακτηριστικών σε χρονοσειρές ποικίλλει ανάλογα με τον σκοπό της ανάλυσης. Ανάμεσα στις δημοφιλέστερες μεθόδους συμπεριλαμβάνονται:

- Μέθοδοι Μετασχηματισμού: Χρησιμοποιούνται για να μετασχηματίσουν τη χρονοσειρά σε ένα νέο χώρο χαρακτηριστικών, όπως τον χώρο των συχνοτήτων με το Fourier ή Wavelet μετασχηματισμό.
- Παράθυρα: Εφαρμόζουν στατιστικά μετρικά (όπως μέσο, διακύμανση) σε παράθυρα του χρονοσειρών για την εξαγωγή χαρακτηριστικών.
- Μετρικά Χαρακτηριστικά: Αποτελούν στατιστικές μετρήσεις που περιγράφουν τη χρονοσειρά, όπως η μέση τιμή, το εύρος, η κλίση κ.α.

### 2.3.2 Επιλογή χαρακτηριστικών

Η επιλογή χαρακτηριστικών αποτελεί μια κρίσιμη φάση στην ανάπτυξη μοντέλων κατηγοριοποίησης, καθώς γίνεται προσπάθεια επιλογής των πλέον σημαντικών χαρακτηριστικών που θα συνεισφέρουν στην αναγνώριση των κλάσεων με βάση τα δεδομένα που είναι διαθέσιμα. Στόχος είναι η μείωση της πολυπλοκότητας του μοντέλου και του χρόνου εκπαίδευσης, διατηρώντας ή αυξάνοντας ταυτόχρονα την απόδοση του. Δημοφιλείς τεχνικές επιλογής χαρακτηριστικών είναι:

1. SelectKBest. Είναι μια τεχνική επιλογής χαρακτηριστικών που βασίζεται στην επιλογή των K καλύτερων χαρακτηριστικών από το σύνολο δεδομένων. Η επιλογή των καλύτερων χαρακτηριστικών γίνεται με βάση μια μετρική, όπως η ANOVA (ανάλυση διασποράς), που αξιολογεί τη συσχέτιση των χαρακτηριστικών με τις κλάσεις.
2. SelectPercentile. Το SelectPercentile είναι μια παραλλαγή του SelectKBest, όπου αντί να επιλέγεται ένα συγκεκριμένο πλήθος χαρακτηριστικών, επιλέγεται ένα ποσοστό του συνόλου των χαρακτηριστικών. Παρόλο που η επιλογή γίνεται με βάση την ίδια μετρική ANOVA ή άλλες μετρικές, το SelectPercentile είναι πιο ευέλικτο και προσαρμόζεται καλύτερα σε διαφορετικά μεγέθη δεδομένων.

Οι μετρικές που χρησιμοποιούνται επιλέγονται κυρίως με βάση τα χαρακτηριστικά των δεδομένων. Ενδεικτικά από τις δημοφιλέστερες είναι:

1. ANOVA-F. Είναι μια στατιστική μέθοδος που χρησιμοποιείται για να εξετάσει αν υπάρχουν σημαντικές διαφορές μεταξύ μέσων των δύο ή περισσότερων ομάδων. Στην κατηγοριοποίηση, χρησιμοποιείται ο ANOVA για την αξιολόγηση για το αν υπάρχουν σημαντικές διαφορές στη μέση τιμή των χαρακτηριστικών μεταξύ των διαφορετικών κλάσεων ή ομάδων που γίνεται η κατηγοριοποίηση. Η στατιστική μέθοδος ANOVA συγκρίνει αυτές τις δύο διαστάσεις διακύμανσης (μεταξύ και εντός των ομάδων) για να καταλήξει σε μια τιμή F (F-value). Εάν η F-value είναι στατιστικά σημαντική (υπερβαίνει ένα κατώφλι πιθανότητας), τότε υπάρχει σημαντική διαφορά μεταξύ των μέσων των χαρακτηριστικών των διαφορετικών κατηγοριών, και έτσι το χαρακτηριστικό αυτό μπορεί να θεωρηθεί σημαντικό για την κατηγοριοποίηση.
2. Chi-Squared. Χρησιμοποιείται για την αξιολόγηση της σχέσης μεταξύ του κάθε χαρακτηριστικού και της κλάσης που προβλέπεται. Αν υπάρχει υψηλή συσχέτιση, τότε το χαρακτηριστικό είναι πιο σημαντικό για την κατηγοριοποίηση. Τα  $\chi^2$  - τεστ μπορούν να χρησιμοποιηθούν για να προσδιορίσουν αν υπάρχει σημαντική διαφορά μεταξύ των αναμενόμενων συχνοτήτων και των παρατηρούμενων συχνοτήτων σε μια ή περισσότερες κατηγορίες, μέσω υπολογισμού του  $\chi^2 = \frac{(\text{πραγματική συχνότητα} - \text{αναμενόμενη συχνότητα})^2}{\text{αναμενόμενη συχνότητα}}$

3. Pearson's Correlation Coefficient. Είναι μια στατιστική μέτρηση που χρησιμοποιείται για να μετρήσει την ισχύ και τη διεύθυνση της γραμμικής συσχέτισης μεταξύ δύο συνεχών μεταβλητών. Σε απλά λόγια, μας δείχνει αν υπάρχει συσχέτιση μεταξύ δύο μετρήσιμων χαρακτηριστικών και πώς κινούνται μαζί. Ο συντελεστής συσχέτισης του Pearson κυμαίνεται από -1 έως 1. Αν είναι κοντά στο 1 τότε υπάρχει θετική συσχέτιση, αν είναι κοντά στο -1 τότε αρνητική συσχέτιση και αν είναι κοντά στο 0 δεν υπάρχει συσχέτιση.

## 2.4 Κανονικοποίηση δεδομένων

Η κανονικοποίηση δεδομένων είναι μια κοινή διαδικασία προεπεξεργασίας που εφαρμόζεται στα δεδομένα πριν από την κατηγοριοποίηση, προκειμένου να βελτιώσει την απόδοση των μοντέλων κατηγοριοποίησης. Στοχεύει να φέρει τα δεδομένα σε μια συγκεκριμένη κλίμακα ή εύρος, ώστε να αποφευχθεί η υπερβολική επιρροή ορισμένων χαρακτηριστικών και να διατηρηθεί η σημασία των διαφόρων χαρακτηριστικών στην κατηγοριοποίηση. Οι δημοφιλέστερες τεχνικές κανονικοποίησης είναι οι ακόλουθες:

1. Min-Max Scaling. Η μέθοδος αυτή μετατρέπει τα δεδομένα σε ένα συγκεκριμένο εύρος, συνήθως μεταξύ 0 και 1. Υπολογίζεται με τον ακόλουθο τύπο:  
$$x_{scaled} = \frac{x_{min} - x}{x_{max} - x_{min}}$$
, όπου  $x$  είναι η αρχική τιμή,  $x_{min}$  η ελάχιστη τιμή του χαρακτηριστικού και  $x_{max}$  η μέγιστη.
2. Z-score. Η μέθοδος αυτή κανονικοποιεί τα δεδομένα στο ίδιο μέσο και την ίδια τυπική απόκλιση. Χρησιμοποιείται ο παρακάτω τύπος:  $x_{scaled} = \frac{x - \mu}{\sigma}$   
όπου  $X$  είναι η αρχική τιμή,  $\mu$  είναι ο μέσος όρος του χαρακτηριστικού και  $\sigma$  είναι η τυπική απόκλιση.

Η κανονικοποίηση των δεδομένων είναι μια τεχνική πολύ σημαντική για την αύξηση της ακρίβειας της κατηγοριοποίησης αλλά και σε ευρύτερα θέματα μηχανικής μάθησης. Αποφεύγει την υπερβολική επιρροή των χαρακτηριστικών που έχουν μεγαλύτερη κλίμακα. Βελτιώνει την απόδοση των μοντέλων κατηγοριοποίησης, ιδιαίτερα όταν χρησιμοποιούνται αλγόριθμοι που επηρεάζονται από την κλίμακα των δεδομένων (π.χ. k-NN, SVM).

## 2.5 Κατηγοριοποίηση δεδομένων

Τα μοντέλα κατηγοριοποίησης δεδομένων αποτελούν ένα σημαντικό κομμάτι της μηχανικής μάθησης και ασχολούνται με τον ταξινομικό προσδιορισμό δειγμάτων σε διαφορετικές κλάσεις, βάσει των χαρακτηριστικών τους. Τα μοντέλα κατηγοριοποίησης εκπαιδεύονται σε ένα σύνολο εκπαίδευσης με γνωστές ετικέτες κλάσεων και στη συνέχεια χρησιμοποιούνται για να κατηγοριοποιήσουν νέα, μη ταξινομημένα δείγματα. Δημοφιλείς τεχνικές που θα αναλυθούν στην επόμενη υποενότητα είναι οι K-Πλησιέστεροι Γείτονες (k-Nearest Neighbors - k-NN), Gradient Boosting, Support Vector Machine (SVM), Νευρωνικά Δίκτυα (Neural Networks) καθώς και υποκατηγορίες τους.

### 2.5.1 K-Nearest Neighbors (k-NN)

Ο αλγόριθμος αυτός βασίζεται στην ιδέα ότι παρατηρήσεις που βρίσκονται κοντά σε παρατηρήσεις κάποιας κλάσης πιθανότατα ανήκουν στην ίδια κλάση. Κατά την ταξινόμηση μιας νέας παρατήρησης, το μοντέλο βρίσκει τους  $k$  πλησιέστερους γείτονες της (k-Nearest Neighbors) και το αναθέτει στην κλάση που εμφανίζεται πιο συχνά ανάμεσα τους. Ως  $k$  επιλέγεται ένας περιττός αριθμός. Η διαδικασία του αλγορίθμου είναι η εξής:

1. Επιλογή του  $k$ . Το  $k$  ορίζεται ως ο αριθμός των πλησιέστερων γειτόνων που θα χρησιμοποιηθούν για την ταξινόμηση μιας παρατήρησης.
2. Για κάθε νέα παρατήρηση υπολογίζεται η απόσταση από όλες τις υπάρχουσες παρατηρήσεις εκπαίδευσης.
3. Με βάση των  $k$  κοντινότερων γειτόνων-παρατηρήσεων ταξινομείται η παρατήρηση στην κλάση που παρατηρείτε περισσότερο στους  $k$  αυτούς γείτονες.

### 2.5.2 Support Vector Machines (SVM)

Τα Support Vector Machines είναι ένα μοντέλο μηχανικής μάθησης που χρησιμοποιείται για την κατηγοριοποίηση και την παλινδρόμηση δεδομένων. Βασική ιδέα των SVM είναι η εύρεση ενός υπερεπιπέδου στον χώρο των χαρακτηριστικών, το οποίο θα είναι σε θέση να διαχωρίσει με τον καλύτερο τρόπο τις παρατηρήσεις. Η διαδικασία μπορεί να περιγραφεί ως εξής:

1. Εκπαίδευση: Κατά την εκπαίδευση γίνεται αναζήτηση του υπερεπιπέδου υποστήριξης που μεγιστοποιεί την απόσταση (περιθώριο) μεταξύ των κλάσεων. Αυτή η απόσταση ονομάζεται "μέγιστο περιθώριο". Τα δείγματα που βρίσκονται πλησιέστερα σε αυτό το υπερεπίπεδο υποστήριξης είναι τα "διανύσματα υποστήριξης".
2. Βελτιστοποίηση: Ο στόχος είναι να βρεθούν τα βάρη (συντελεστές) του υπερεπιπέδου υποστήριξης έτσι ώστε να ελαχιστοποιείται η απώλεια (σφάλμα ταξινόμησης) και ταυτόχρονα να μεγιστοποιείται το περιθώριο. Αυτό αντιστοιχεί στην επίλυση ενός προβλήματος βελτιστοποίησης.
3. Πρόβλεψη: Αφού ολοκληρωθεί η εκπαίδευση, το SVM μπορεί να χρησιμοποιηθεί για την πρόβλεψη των κλάσεων νέων δεδομένων. Η ταξινόμηση των δεδομένων σε κλάσεις γίνεται βασιζόμενο στη θέση του σε σχέση με το υπερεπίπεδο υποστήριξης και τη θέση των διανυσμάτων υποστήριξης.

Σημαντικές παράμετροι των SVM είναι ο Πυρήνας (Kernel) και η Παραμετροποίηση  $C$ . Ο πυρήνας αναπαριστά μια κεντρική έννοια στα SVM. Σε προβλήματα όπου τα δεδομένα δεν μπορούν να χωριστούν γραμμικά, οι πυρήνες επιτρέπουν τον μετασχηματισμό τους σε έναν χώρο υψηλότερης διάστασης, όπου η διαχωριστική επίλυση μπορεί να είναι γραμμική. Αυτό επιτρέπει στα SVM να αντιμετωπίζουν προβλήματα που δεν είναι γραμμικά διαχωρίσιμα. Κάθε πυρήνας αντιστοιχεί σε μια συγκεκριμένη συνάρτηση μετασχηματισμού, όπως η σιγμοειδή, γραμμική κ.α.

Η παράμετρος  $C$  ελέγχει την εξισορρόπηση μεταξύ της ακρίβειας ταξινόμησης και του περιθωρίου. Η τιμή του  $C$  καθορίζει πόσο αυστηρά τα SVM θα εφαρμόζουν το περιθώριο. Όταν το  $C$  είναι χαμηλό, τα SVM επιτρέπουν περισσότερες παραβιάσεις του περιθωρίου, καθιστώντας την ταξινόμηση πιο ευέλικτη, αλλά πιο πιθανό να παρουσιάζει υπερ-προσαρμογή (overfitting). Αντίθετα, όταν το  $C$  είναι υψηλό, τα SVM είναι πιο αυστηρά και επιβάλλουν μικρότερη παραβίαση του περιθωρίου. Αυτό μπορεί να οδηγήσει σε μεγαλύτερη γενίκευση, αλλά μπορεί να προκαλέσει υπο-προσαρμογή (underfitting) αν τα δεδομένα είναι πολύ πολύπλοκα.

### 2.5.3 Gradient boosting

Το Gradient boosting είναι μια τεχνική μηχανικής μάθησης που χρησιμοποιείται για προβλήματα ανάλυσης και πρόβλεψης. Είναι μια μέθοδος σύνθεσης πολλαπλών αδύναμων μοντέλων, συνήθως δέντρων αποφάσεων (Ensemble learning), για την δημιουργία ενός ισχυρού μοντέλου πρόβλεψης. Το Gradient boosting βασίζεται στον αλγόριθμο του Gradient descent, στο οποίο γίνεται προσπάθεια για εύρεση του βέλτιστου συνδυασμού αδύναμων μοντέλων ελαχιστοποιώντας το σφάλμα (ή τη συνάρτηση κόστους).

1. Το πρώτο βήμα είναι η δημιουργία ενός αρχικού μοντέλου  $F_0$  το οποίο είναι η εκτίμηση του στόχου  $y$ , σύμφωνα με τον παρακάτω τύπο. Όπου  $L$  είναι η συνάρτηση απώλειας.

$$L = (y_i - \gamma)^2$$

$$F_0(x) = \operatorname{argmin}_{\gamma} \sum_i L(y_i, \gamma)$$

- 2-1. Για κάθε παράδειγμα  $i$  υπολογίζεται το υπόλειμμα (διαφορά πραγματικής και επιθυμητής τιμής). Θεωρούμε τα συνολικά παραδείγματα ίσα με  $M$ .

$$r_{im} = - \left[ \frac{\partial L(y_i, F(x_i))}{\partial F(x_i)} \right]_{F(x)=F_{m-1}(x)} \quad \text{for } i = 1, \dots, n$$

- 2-2 Εκπαίδευση νέου μοντέλου προσαρμόζοντάς το στα υπολείμματα (residuals).

- 2-3 Υπολογισμός νέων υπολοίπων. Γίνεται αναζήτηση του  $\gamma_{jm}$  για κάθε τερματικό κόμβο  $j$  ο οποίος ελαχιστοποιεί το σφάλμα.

$$\gamma_{jm} = \operatorname{argmin}_{\gamma} \sum_i L(y_i, F_{m-1}(x_i) + \gamma) \quad \text{for } j = 1, \dots, J_m$$

Προκύπτει ότι το  $\gamma_{jm}$  που ελαχιστοποιεί τη συνάρτηση απώλειας είναι ο μέσος όρος των υπολειμμάτων.

- 2-4 Ενημέρωση μοντέλου.

$$F_m(x) = F_{m-1}(x) + \nu \sum_{j=1}^{J_m} \gamma_{jm} 1(x \in R_{jm})$$

Το  $\nu$  είναι ο ρυθμός εκμάθησης (learning rate) το οποίο είναι από 0 μέχρι 1. Ένας μικρότερος ρυθμός εκμάθησης μειώνει την επίδραση της πρόσθετης πρόβλεψης δέντρου, αλλά επίσης μειώνει επίσης την πιθανότητα υπερβολικής προσαρμογής του μοντέλου στα δεδομένα εκπαίδευσης.

3. Επανάληψη βημάτων 2-1 – 2-4 με κάθε νέο μοντέλου που προστίθεται βελτιώνει την προσέγγιση του τελικού μοντέλου στα δεδομένα.

## 2.6 Κατηγοριοποίηση δεδομένων με χρήση νευρωνικών δικτύων


Τα νευρωνικά δίκτυα αποτελούν μια κατηγορία μεθόδων στην τεχνητή νοημοσύνη που πηγάζουν από την αναπαράσταση των βιολογικών νευρωνικών δικτύων και αποσκοπούν στο να προσεγγίσουν πολύπλοκες συναρτήσεις και περίπλοκα προβλήματα, με εφαρμογές που εκτείνονται από τη μηχανική όραση μέχρι τη φυσική γλώσσα και τη ρομποτική. Σε βασικό επίπεδο, τα νευρωνικά



δίκτυα αποτελούνται από διατάξεις απλών μονάδων επεξεργασίας, γνωστές ως νευρώνες, οι οποίες λειτουργούν σε παράλληλη διαμόρφωση και αλληλεπίδραση. Τα νευρωνικά δίκτυα διαχωρίζονται με βάση την αρχιτεκτονική τους

### 2.6.1 Λειτουργία τεχνητού νευρώνα

Ο τεχνητός νευρώνας αντιπροσωπεύει ένα βασικό στοιχείο ενός νευρωνικού δικτύου. Σε κάθε "κόμβο" του δικτύου, λαμβάνεται ένα σύνολο αριθμητικών εισόδων μέσω συνδέσεων, και με βάση αυτές τις εισόδους, παράγεται μια "έξοδος" χρησιμοποιώντας μια συνάρτηση μεταφοράς. Υπάρχουν τρεις τύποι νευρώνων: οι νευρώνες εισόδου, οι νευρώνες εξόδου και οι κρυμμένοι νευρώνες.



Εικόνα 3. Δομή Τεχνητού Νευρώνα

Οι νευρώνες εισόδου λαμβάνουν απλώς τις αρχικές εισόδους του δικτύου και τις προωθούν προς τους κρυμμένους νευρώνες, χωρίς να εκτελούν υπολογισμούς. Οι νευρώνες εξόδου αναλαμβάνουν να παράγουν την τελική έξοδο του δικτύου που επιθυμούμε να αποκτήσουμε. Το κύριο κομμάτι είναι οι κρυμμένοι νευρώνες. Οι κρυμμένοι νευρώνες πραγματοποιούν πολλαπλασιασμό των εισόδων τους με τα αντίστοιχα "βάρη" συνδέσεων και υπολογίζουν το άθροισμα των πολλαπλασιασμένων τιμών. Αυτό το άθροισμα στη συνέχεια περνάει μέσα από μια συνάρτηση "ενεργοποίησης", η οποία εφαρμόζει μια μη γραμμική λειτουργία στο άθροισμα και παράγει την τελική έξοδο του νευρώνα. Επίσης, υπάρχει η δυνατότητα να προστεθεί μια σταθερά (γνωστή και ως "bias") στο άθροισμα, η οποία μετατοπίζει την συνάρτηση ενεργοποίησης και επηρεάζει την τελική έξοδο του νευρώνα. Συνολικά, ο τεχνητός νευρώνας λειτουργεί ως μια μικρή υπολογιστική μονάδα που εκτελεί διαδικασίες υπολογισμών και μετασχηματισμών πάνω στις εισόδους του, προκειμένου να παράγει μια τελική έξοδο.

### 2.6.2 Συνάρτηση μεταφοράς

Ως συνάρτηση μεταφοράς του νευρώνα μπορούμε να χρησιμοποιήσουμε ένα πλήθος συναρτήσεων. Η επιλογή γίνεται με βάση την εφαρμογή, με στόχο την μέγιστη δυνατή αποτελεσματικότητα του νευρωνικού δικτύου. Δεν είναι απαραίτητο όλοι οι νευρώνες να υλοποιούν

την ίδια συνάρτηση μεταφοράς. 4 Βασικοί τύποι συναρτήσεων είναι η βηματική, η τμηματικά γραμμική (Relu) ,η σιγμοειδής και η softmax.

$$\text{Βηματική Συνάρτηση } Y(x) = \begin{cases} 0, & x < 0 \\ 1, & x \geq 0 \end{cases}$$

$$\text{Relu } Y(x) = \begin{cases} 0, & x < 0 \\ x, & x \geq 0 \end{cases}$$

$$\text{Σιγμοειδής } y(x) = \frac{1}{1 + e^{-x}}$$

$$\text{Softmax}(x)_i = \frac{e^{x_i}}{\sum_{j=1}^n e^{x_j}}$$

### 2.6.3 Κατηγορίες νευρωνικών δικτύων

Οι κατηγορίες νευρωνικών δικτύων περιλαμβάνουν διάφορες αρχιτεκτονικές και δομές που έχουν αναπτυχθεί για να αντιμετωπίσουν διαφορετικούς τύπους προβλημάτων και εφαρμογών. Οι κυριότερες κατηγορίες είναι οι εξής:

1. Πολυεπίπεδα πλήρως συνδεδεμένα δίκτυα (Fully Connected Feedforward Networks - FFNs). Σε αυτά οι νευρώνες σε κάθε στρώμα συνδέονται πλήρως με τους νευρώνες του προηγούμενου και του επόμενου στρώματος. Είναι κατάλληλα για προβλήματα όπως η κατηγοριοποίηση και η παλινδρόμηση.
2. Συνελκτικά δίκτυα (Convolutional Neural Networks - CNNs). Ειδικά σχεδιασμένα για επεξεργασία δεδομένων με χωρική δομή, όπως εικόνες. Χρησιμοποιούν φίλτρα για την εντοπισμό χαρακτηριστικών σε διαφορετικά επίπεδα της εικόνας.
3. Τεχνητά νευρωνικά δίκτυα με ανατροφοδότηση (Recurrent Networks - RNNs). Στα δίκτυα με ανατροφοδότηση είναι εφικτό να έχουμε βρόχους, καθώς το σήμα μπορεί να έχει 2 κατευθύνσεις. Είναι δυναμικά περίπλοκα και σαφώς δυσκολότερα να εκπαιδευτούν, αλλά προσεγγίζουν περισσότερο τα βιολογικά δίκτυα. Έχουν την ικανότητα να «συγκρατούν» πληροφορίες για μεγάλο διάστημα. Κατηγορίες αυτών είναι τα LSTM (Long Short-Term Memory - LSTM) και (Gated Recurrent Units - GRUs).
4. Transformer Networks. Χρησιμοποιούνται ευρέως για επεξεργασία ακολουθιών κειμένου και φωνής. Εισήχθησαν για την αντιμετώπιση του προβλήματος της μακροπρόθεσμης εξάρτησης στις ακολουθίες.

### 2.6.4 Εκπαίδευση νευρωνικών δικτύων

Πρωταρχικό βήμα μετά τον σχεδιασμό και υλοποίηση ενός νευρωνικού δικτύου είναι η εκπαίδευση του. Τα 3 είδη εκπαίδευσης είναι τα εξής:

1. Εκπαίδευση με επίβλεψη (Supervised Training). Σε αυτήν υπάρχει ένα σύνολο εισόδων (χαρακτηριστικά) και οι αντίστοιχες επιθυμητές εξόδους (ετικέτες ή σωστές απαντήσεις). Κατά τη διάρκεια της εκπαίδευσης, το μοντέλο επιδιώκει να μάθει τη σχέση μεταξύ των χαρακτηριστικών και των ετικετών, έτσι ώστε να μπορεί να κάνει προβλέψεις για νέες εισόδους. Ο στόχος είναι να ελαχιστοποιηθεί η διαφορά μεταξύ των προβλέψεων του μοντέλου και των πραγματικών εξόδων.

2. Εκπαίδευση χωρίς επίβλεψη (Unsupervised Training). Σε αυτήν την μορφή εκπαίδευσης δεν υπάρχουν προκαθορισμένες ετικέτες. Το μοντέλο εκπαιδεύεται να ανακαλύπτει μοτίβα ή δομές στα δεδομένα, χωρίς προγενέστερη γνώση για το τι αναζητεί.
3. Εκπαίδευση με ενίσχυση (Reinforcement Learning). Είναι ένα πλαίσιο όπου ένα αλγόριθμος μάθησης εκπαιδεύεται να λαμβάνει αποφάσεις σε ένα περιβάλλον προκειμένου να μεγιστοποιήσει μια ανταμοιβή. Το μοντέλο αλληλοεπιδρά με το περιβάλλον, παίρνοντας δράσεις και λαμβάνοντας ανταμοιβές ή ποινές, και στη συνέχεια προσαρμόζεται για να μάθει τη βέλτιστη στρατηγική για το πρόβλημα.

Η πιο διαδεδομένη μορφή εκπαίδευσης με επίβλεψη είναι η τεχνική backpropagation, η οποία υπολογίζει αποτελεσματικά την κλίση της συνάρτησης σφάλματος σε σχέση με τα βάρη του δικτύου για ένα μόνο παράδειγμα εισόδου-εξόδου. Υπολογίζει την συνάρτηση σφάλματος για ένα επίπεδο την φορά, ξεκινώντας από το ανώτερο επίπεδο (layer) και καταλήγοντας στο επίπεδο εισόδου. Η ενημέρωση των βαρών στον αλγόριθμο αυτό γίνεται σύμφωνα με τους παρακάτω τύπους.

$$w_j^r(new) = w_j^r(old) + \Delta w_j^r \quad (2.1)$$

$$\Delta w_j^r = -\mu \sum_{i=1}^N \delta_j^r(i) y^{r-1}(i) \quad (2.2)$$

$$\delta_j^L(i) = e_j(i) f'(u_j^L(i)) \quad (2.3)$$

$$\delta_j^{r-1} = e_j^{r-1}(i) f'(u_j^{r-1}(i)) \quad (2.4)$$

$$e_j^{r-1} = \sum_{k=1}^{k_r} \delta_k^r(i) w_{kj}^r \quad (2.5)$$

## 2.6.5 Convolutional Neural Network (CNN)

Τα Convolutional Neural Networks (CNN) αποτελούν ένα σημαντικό εργαλείο στον τομέα της επεξεργασίας εικόνας και ανάλυσης προτύπων. Αυτή η κατηγορία νευρωνικών δικτύων έχει σχεδιαστεί με γνώμονα την αξιοποίηση της δομής και των χαρακτηριστικών των εικόνων, προσφέροντας προηγμένες δυνατότητες ανίχνευσης και αναγνώρισης προτύπων. Τα βασικά συστατικά των CNNs αναλύονται στις παρακάτω παραγράφους.

Η συνέλιξη είναι η βασική λειτουργία ενός CNN. Αντιστοιχίζει ένα μικρό φίλτρο (ή πυρήνα) πάνω στην εικόνα και υπολογίζει την σύνοψη των πολλαπλασιασμών των pixels της εικόνας με τις αντίστοιχες τιμές του φίλτρου. Αυτό προκαλεί τη δημιουργία ενός νέου χάρτη χαρακτηριστικών (feature map), που καταγράφει την ανίχνευση συγκεκριμένων χαρακτηριστικών (όπως ακμές ή γωνίες).

Η υποδειγματοληψία είναι μια διαδικασία που μειώνει τη διάσταση του χάρτη χαρακτηριστικών, διατηρώντας τα βασικά χαρακτηριστικά. Η πιο συνηθισμένη μορφή υποδειγματοληψίας είναι η Max Pooling, όπου κάθε περιοχή του χάρτη χαρακτηριστικών διαιρείται σε μικρότερα τμήματα και επιλέγεται το μέγιστο στοιχείο.

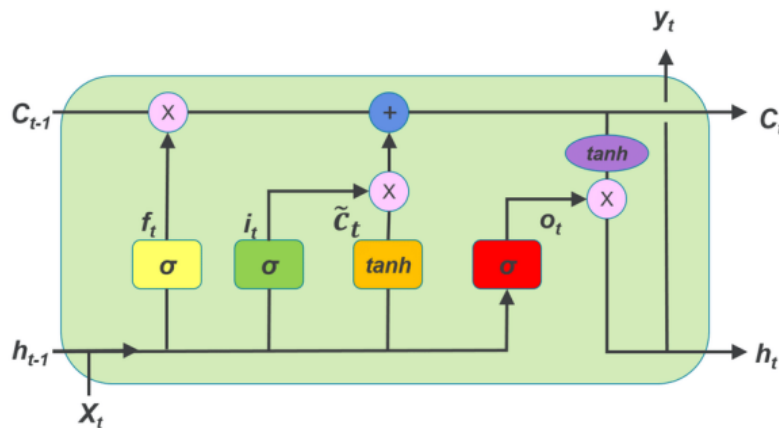
Τα πλήρως διασυνδεδεμένα επίπεδα ακολουθούν τα στάδια της συνέλιξης και της υποδειγματοληψίας. Στα πλήρως διασυνδεδεμένα επίπεδα, όλοι οι νευρώνες συνδέονται με όλους τους νευρώνες του προηγούμενου επιπέδου. Αυτά τα επίπεδα χρησιμοποιούνται για την ταξινόμηση ή την εκτίμηση των επιπέδων χαρακτηριστικών που έχουν εξάγει τα προηγούμενα επίπεδα.

### 2.6.6 Long-Short Term Memory (LSTM) network

Οι Long Short-Term Memory (LSTM) αρχιτεκτονικές είναι εξελιγμένα νευρωνικά δίκτυα που χρησιμοποιούνται ευρέως για την ανάλυση χρονοσειρών και την επεξεργασία σειρών δεδομένων με χρονική διάσταση. Όπως αναφέρθηκε και στην ενότητα [2.6.3] ανήκουν στην κατηγορία των τεχνητών νευρωνικών δικτύων με ανατροφοδότηση (Recurrent Networks). Τα LSTM διαθέτουν ειδικούς μηχανισμούς που επιτρέπουν την διατήρηση και την ανάκτηση πληροφορίας σε διάφορες χρονικές κλίμακες, διαχειρίζοντας τις μακροπρόθεσμες εξαρτήσεις και τις ανωμαλίες. Στο εσωτερικό ενός LSTM κελιού, υπάρχουν τρία βασικά στοιχεία:

1. Cell state ( $C_t$ ): Αυτός είναι ο πυρήνας της μνήμης του κελιού και αποθηκεύει τις πληροφορίες από προηγούμενες εισόδους και εκτελεί τόσο τις βραχυπρόθεσμες όσο και τις μακροπρόθεσμες εξαρτήσεις. Ανανεώνεται μέσω μιας σειράς μαθηματικών λειτουργιών.
2. Hidden state ( $h_t$ ): Είναι η τιμή εξόδου που προκύπτει από την τρέχουσα είσοδο και χρησιμοποιείται ως είσοδος για τα επόμενα κελιά.
3. Gates (Forget gate, Input gate, Output gate): Τα gates είναι μηχανισμοί που ελέγχουν τη ροή των πληροφοριών στο και από το κελί. Το Forget gate ( $f_t$ ) αποφασίζει ποιες πληροφορίες αφαιρούνται από το cell state, το Input gate ( $i_t$ ) προσθέτει νέες πληροφορίες στο cell state, και το Output gate ( $O_t$ ) επιλέγει ποιες πληροφορίες από το cell state θα οδηγήσουν στην έξοδο.

Οι πύλες λειτουργούν ως φίλτρα που επιτρέπουν τη ροή των πληροφοριών. Για την ρύθμιση των τιμών των πυλών εκτελούνται πράξεις πολλαπλασιασμού και πρόσθεσης. Οι τελικές τιμές των πυλών καθορίζονται μέσω σιγμοειδών και tanh συναρτήσεων ενεργοποίησης. Με την χρήση αυτών των προηγμένων μηχανισμών, τα LSTM επιτυγχάνουν την αποτελεσματική αναπαράσταση και ανάκτηση πληροφορίας σε χρονοσειρές.



Εικόνα 4. Το LSTM κύτταρο

Παρακάτω ακολουθούν οι εξισώσεις που προκύπτουν:

$$f(t) = \sigma(w_{xf}^T x(t) + h(t-1) + b_f)$$

$$i(t) = \sigma(w_{xi}^T x(t) + h(t-1) + b_i)$$

$$o(t) = \sigma(w_{xo}^T x(t) + h(t-1) + b_o)$$

$$\tilde{c}(t) = g(t) = \tanh(w_{xg}^T \times (t) + w_{xg}^T h(t-1) + b_g)$$

$$c(t) = f(t) \otimes c(t-1) + i(t) \otimes g(t)$$

$$h(t) = y(t) = o(t) \otimes \tanh(c(t))$$

Η διαδικασία εκπαίδευσης του δικτύου LSTM υλοποιείται μέσω του backpropagation, μία μέθοδο μαθηματικής ανανέωσης των βαρών. Οι εξισώσεις είναι περίπλοκες και περιλαμβάνουν τη διάδοση των διαφορικών μεταβολών από την έξοδο προς την είσοδο μέσω των πυλών και των καταστάσεων του LSTM.

## ΚΕΦΑΛΑΙΟ 3

# ΕΦΑΡΜΟΓΗ ΕΞΑΓΩΓΗΣ ΧΑΡΑΚΤΗΡΙΣΤΙΚΩΝ ΚΑΙ ΚΑΤΗΓΟΡΙΟΠΟΙΗΣΗΣ


Για τις ανάγκες της παρούσας διπλωματικής εργασίας, πραγματοποιήθηκε η σχεδίαση και η ανάπτυξη πηγαίου κώδικα με σκοπό τη δημιουργία μιας εφαρμογής. Η εν λόγω εφαρμογή επικεντρώνεται στην εκτέλεση και τη δοκιμή διαφορετικών μοντέλων, μεθόδων επεξεργασίας των δεδομένων, καθώς και εξαγωγή και αξιοποίηση των χαρακτηριστικών. Η εφαρμογή διαθέτει το κατάλληλο interface έτσι ώστε να προθέτονται άμεσα και εύκολα νέα μοντέλα και μέθοδοι επεξεργασίας. Στόχος της είναι η κατηγοριοποίηση των χρονοσειρών των συμμετεχόντων του προγράμματος frailsafe σε 3 κλάσεις (ή και 2) ανάλογα με την ευπάθεια τους. Οι κλάσεις αυτές είναι οι εξής: frail, non-frail, pre-frail.

### 3.1 Αρχιτεκτονική

Η εφαρμογή σχεδιάστηκε σε γλώσσα προγραμματισμού Python. Η έκδοση που δοκιμάστηκε και για την οποία υλοποιήθηκε είναι η 3.8.10. Η Python είναι διερμηνευόμενη (interpreted), γενικού σκοπού (general-purpose) και υψηλού επιπέδου, γλώσσα προγραμματισμού. Ο λόγος που επιλέχθηκε είναι ότι διαθέτει ευρεία γκάμα βιβλιοθηκών για εύκολο χειρισμό δεδομένων από αρχεία και βάσεις δεδομένων, αλλά και κυρίως στον τομέα της μηχανικής μάθησης. Παράλληλα χαρακτηριστικό της είναι η αναγνωσιμότητα του κώδικα της και η ευκολία χρήσης της.

Η βάση δεδομένων που επιλέχθηκε στην παρούσα εφαρμογή είναι η ArangoDB. Η ArangoDB είναι ένα δωρεάν και ανοιχτού κώδικα εγγενές σύστημα βάσεων δεδομένων πολλαπλών μοντέλων που αναπτύχθηκε από την ArangoDB GmbH. Είναι ένα σύστημα βάσης δεδομένων NoSQL. Η γλώσσα ερωτήματος (query language) που περιλαμβάνει ονομάζεται AQL (ArangoDB Query Language) είναι δηλωτική και επιτρέπει τον συνδυασμό διαφορετικών προτύπων πρόσβασης δεδομένων σε ένα μόνο ερώτημα.

Η εφαρμογή αποτελείται από 3 ξεχωριστά μέρη (components). Το πρώτο λειτουργεί εντελώς αυτόνομα και μπορεί να τροφοδοτεί την βάση δεδομένων με δεδομένα που αντλούνται από τα κατάλληλα αρχεία. Το δεύτερο, προϋποθέτει την ύπαρξη δεδομένων στην βάση (που γίνεται μέσω του πρώτου component) και έχει σκοπό να επεξεργαστεί τις χρονοσειρές και να εξάγει τα κατάλληλα χαρακτηριστικά. Το τρίτο υποστηρίζει την εκτέλεση διαφόρων μεθόδων κατηγοριοποίησης και επεξεργασίας δεδομένων. Ο χρήστης έχει την δυνατότητα να δώσει ως παράμετρο διαφόρους συνδυασμούς αυτών και να λάβει τα αντίστοιχα αποτελέσματα. Όλα τα components εκτελούνται από το αρχικό μονοπάτι μέσω του αρχείου run\_module.py.



Εικόνα 5. Στιγμιότυπο από την εφαρμογή

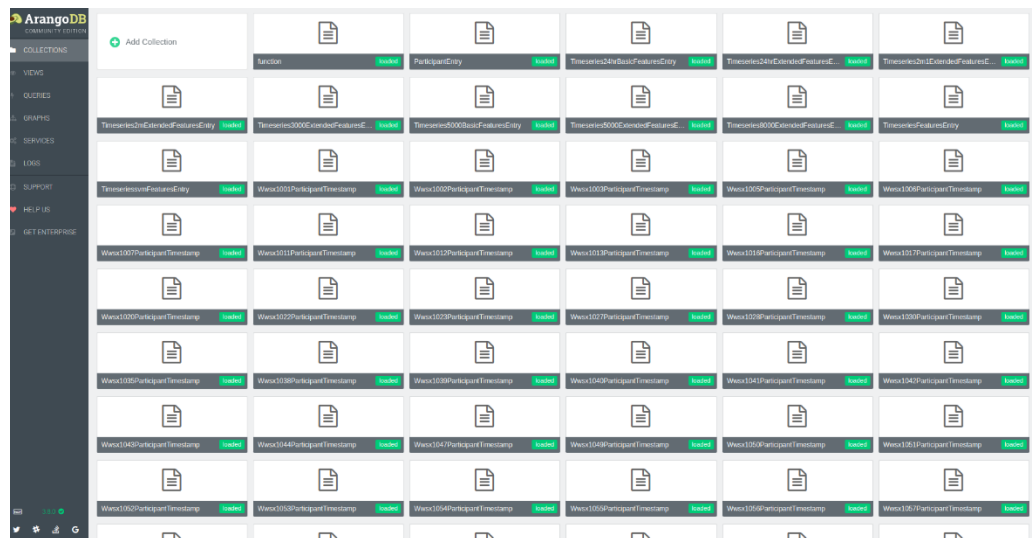
Στο εξωτερικό μονοπάτι της εφαρμογής υπάρχουν τα παρακάτω αρχεία .py.

1. “database\_setup.py”. Αναλαμβάνει να υλοποιήσει την βάση δεδομένων μέσω της βιβλιοθήκης python-arango. Δέχεται ως παραμέτρους την πόρτα (port) της διεπαφής που του docker container που θα δημιουργηθεί για να φιλοξενήσει την βάση δεδομένων. Επίσης δέχεται ως παράμετρο τον κωδικό root.
2. “run\_module.py”. Είναι ένα αρχείο το οποίο αναλαμβάνει την εκτέλεση όλων των components από το εξωτερικό path.
3. “settings.py”. Περιλαμβάνει τους κωδικούς της βάσεις δεδομένων, το path της βάσεις δεδομένων καθώς και άλλες παραμέτρους που ρυθμίζουν την λειτουργία της εφαρμογής.

Παράλληλα, υπάρχουν και κάποιοι φάκελοι που εμπεριέχουν αρχεία .py τα οποία επίσης απαρτίζουν δομικά συστατικά του πηγαίου κώδικα. Εξαίρεση αποτελούν ο φάκελος data που εμπεριέχει τα αρχικά δεδομένα σε μορφή .mat καθώς και ο φάκελος logs που εμπεριέχει αρχεία .txt με τις ακρίβειες και τα στατιστικά των αποτελεσμάτων. Οι φάκελοι που εμπεριέχουν τον υπόλοιπο πηγαίο κώδικα είναι οι εξής:

1. “participant\_source”. Εμπεριέχει το αρχείο participant\_source\_base.py και έναν φάκελο plugins. Το participant\_source\_base.py εμπεριέχει μια κλάση η οποία χρησιμοποιείται ως υπερκλάση όλων των κλάσεων που θα δημιουργηθούν στα αντίστοιχα αρχεία στον φάκελο plugins. Το component αυτό αναλαμβάνει να εξάγει τα δεδομένα από τα αρχεία .mat , να τα επεξεργαστεί σε μορφή κατάλληλη για την βάση δεδομένων , καθώς και να τα γράψει σε αυτήν.
2. “models\_manager”. Εμπεριέχει τα αρχεία network\_manager.py και feature\_extractor.py . Το network\_manager.py αναλαμβάνει την εκτέλεση διαφόρων μεθόδων επεξεργασίας δεδομένων και μοντέλων ταξινόμησης σε 3 κλάσεις (ή και 2). Αξιοποιεί τα δεδομένα που ανέλαβε να γράψει στην βάση δεδομένων το αρχείο feature\_extractor.py. Το feature\_extractor.py δέχεται ως κυριότερες παραμέτρους το μέγεθος του παραθύρου σε millisecond κατά τα οποία θα γίνεται κάθε εξαγωγή χαρακτηριστικών καθώς και το αν θα εξαχθούν τα βασικά ή τα πιο εκτεταμένα χαρακτηριστικά.
3. “support”. Περιλαμβάνει διάφορα αρχεία με κλάσεις του συστήματος και την διεπαφή τους με τα αντίστοιχα collections στην ArangoDB. Αυτά είναι τα participant\_entry.py και το timeseries\_features.py . Επίσης υπάρχει το αρχείο connect\_with\_db.py το οποίο περιλαμβάνει κάποιες εκτελέσεις AQL (ερωτήσεις στην ArangoDB) υπό μορφή συναρτήσεων της python για ταχύτερη επεξεργασία των δεδομένων. Επίσης περιλαμβάνει την διεπαφή που εμπεριέχεται ως υπερκλάση σε όλες τις κλάσεις που επιθυμούμε να γράψουμε ή να

διαβάσουμε από την βάση δεδομένων. Αυτή εμπεριέχει μεθόδους `db_read` και `db_write` για τους αντίστοιχους σκοπούς.



Εικόνα 6. Στιγμιότυπο από την ArangoDB

## 3.2 Η εξαγωγή χαρακτηριστικών

Όπως αναφέρθηκε και σε προηγούμενη ενότητα, την εξαγωγή χαρακτηριστικών αναλαμβάνει το αρχείο `feature_extractor.py` και η κλάση `FeatureExtractor`, η οποία εμπεριέχεται στο αρχείο αυτό. Η κλάση αυτή εμπεριέχει την μέθοδο `extract_features_from_smart_dataset`. Ονομάστηκε έτσι καθώς χρησιμοποιεί μόνο μετρήσεις οι οποίες εξάγονται από ένα smartwatch. Αυτές είναι οι εξής:

1. `ecg_heart_rate`. Καρδιακός ρυθμός. Heart rate (value: Beats/minute - sampling rate: 1/5 sec)
2. `ecg_heart_rate_variability` Μεταβλητότητα καρδιακού ρυθμού. Heart rate variability (value: ms - sampling rate: 1/60 sec)
3. `ecg_signal_quality`. Ποιότητα σήματος ECG. ECG signal quality (value: 0-255 where 0=poor and 255=excellent - sampling rate: 1/5 sec)
4. `ecg_rr_interval`. Τα δείγματα ανάμεσα σε δύο κορυφές στο ECG . R-R intervals (value: number of samples between R-R peaks - sampling rate: 1/5 sec)
5. `acceleration_x`. Επιταχυνσιόμετρο στον άξονα X.
6. `acceleration_y`. Επιταχυνσιόμετρο στον άξονα Y.
7. `acceleration_z`. Επιταχυνσιόμετρο στον άξονα Z.
8. `breathing_rate`. Ρυθμός αναπνοής.

Σε ορισμένες μετρήσεις συμπεριελήφθησαν και 1 ακόμη μέτρηση η οποία μπορεί να εξαχθεί και αυτή από ένα smartwatch αυτόματα είτε να την δώσει ως είσοδο ο χρήστης σε αυτό. Αυτή αναφέρεται στην κατηγορία της άσκησης ή στην κατάσταση στην οποία βρίσκεται ο συμμετέχων. Αυτή είναι οι εξής:

1. `activity_class`. Άσκηση ή κατάσταση.

. Η διαφοροποίηση των μετρήσεων που θα συμπεριληφθούν στην μέθοδο γίνεται μέσω της παραμέτρου `attribute_size`, το οποίο παίρνει τιμές «Basic» και «Full» αντίστοιχα.



Στην μέθοδο αυτή δίνονται ως παράμετροι που φαίνονται στην εικόνα 3.3. Η παράμετρος `device_source` δηλώνει από που προέρχονται τα δεδομένα που θα επεξεργαστούν. Καθώς κατά την εκτέλεση του `frailsafe project` δεν έγιναν μετρήσεις μέσω `smartwatch`, οι αντίστοιχες μετρήσεις παίρνονται από άλλη συσκευή, την `wwsx`. Το γιλέκο αυτό δίνει την δυνατότητα για πολλές μετρήσεις και με αρκετά καλή ακρίβεια. Θα χρησιμοποιηθούν μόνο οι μετρήσεις όμως που μπορούν να αντληθούν από ένα `smartwatch`, όπως αναφέρθηκε και προηγουμένως. Επιπλέον η παράμετρος `skip_multi_health_status_participant` αν πάρει τιμή `True`, απορρίπτονται από τις εξαγωγές χαρακτηριστικών ασθενείς που δεν διατήρησαν σταθερή την κατάσταση της υγείας τους κατά την διάρκεια των μετρήσεων. Στις μετέπειτα μετρήσεις χρησιμοποιήθηκε μόνο με τιμή `False`. Το `window_time_size` παίρνει ως τιμή τον χρόνο σε `milliseconds` στον οποίον γίνεται η κάθε εξαγωγή των χαρακτηριστικών. Το `window_time_name` αναφέρεται `window_time_size` που αναφέρθηκε προηγουμένως αλλά με την μορφή αναγνωριστικού. Τα `series_size` και `series_size_name` είναι αντίστοιχα με τα προηγούμενα, διαφοροποιούνται όμως στο γεγονός ότι αφορούν ακολουθίες συνεχόμενων δειγμάτων και όχι χρονικά παράθυρα. Το `features_size` παίρνει τις τιμές «Basic», «Extended», «Full».

```
def extract_features_from_smartwatch_dataset(self,
                                                device_source='wwsx',
                                                skip_multi_health_status_participants=False,
                                                window_time_size=1000 * 60 * 60 * 24,
                                                window_time_name='24hr',
                                                series_size=None,
                                                series_size_name=None,
                                                features_size='Basic',
                                                attribute_size='Basic',
                                                features_per_activity=False
                                                ):

```

Εικόνα 7. Η διεπαφή της `extract_features_from_dataset`

Τα χαρακτηριστικά που αναφέρονται για την τιμή «Basic» είναι τα εξής:

1. `sum_values` (Άθροισμα των τιμών).
2. `median` (Η διάμεσος των τιμών).
3. `length` (Ο αριθμός των μετρήσεων)
4. `standard_deviation` (Η τυπική απόκλιση)
5. `variance` (Η Διακύμανση).
6. `maximum` (Η μέγιστη τιμή).
7. `minimum` (Η ελάχιστη τιμή).
8. `mean` (Η μέση τιμή).

Στην τιμή «Extended» ή «Full» αναφέρονται όλα αυτά της «Basic» καθώς και επιπρόσθετα τα εξής:

1. `kurtosis`. (Κύρτωση).
2. `abs_energy` (Ενέργεια).
3. `skewness` (Ασυμμετρία).

Στην μέθοδο η εξαγωγή των χαρακτηριστικών γίνεται αξιοποιώντας την βιβλιοθήκη της `python tsfresh`.

### 3.3 Η διεπαφή εκτέλεσης της προεπεξεργασίας δεδομένων και των μοντέλων κατηγοριοποίησης

Η εκτέλεση και οι δοκιμές όλων των μοντέλων αλλά και των αλγορίθμων προεπεξεργασίας δεδομένων γίνεται μέσω της μεθόδου `evaluate_models_with_features`. Η μέθοδος αυτή αναλαμβάνει να εκτελέσει για αριθμό δοκιμών που δίνονται ως είσοδο συγκεκριμένα μοντέλα και αλγορίθμους και επιστρέφονται οι αντίστοιχες μετρικές αξιολόγησης. Αυτό υλοποιείται μέσω της μεθόδου `train_model_via_features`. Οι κυριότεροι παράμετροι στην μέθοδο αυτή είναι οι εξής:

1. “model”. Αναφέρεται στο μοντέλο που θα χρησιμοποιεί για κατηγοριοποίηση. Έγκυρες τιμές είναι οι μεταξύ άλλων είναι και οι `ann,knn,gradientboosting,svm,lstm`.
2. “data\_processing\_algorithm”. Αφορά τον αλγόριθμο που θα χρησιμοποιηθεί για την αντιμετώπιση του προβλήματος των μη ισορροπημένων δεδομένων. Έγκυρες τιμές σε αυτό είναι οι `smote, hybrid,tomeklinks, nearmiss, weights` και `None`.
3. “feature\_selection\_method”. Αφορά τον αλγόριθμο επιλογής χαρακτηριστικών. `None` για μη χρήση τέτοιου αλγορίθμου και `selectkBest` ή `selectPercentile` για χρήση του αντίστοιχου αλγορίθμου.
4. “feature\_selection\_size”. Είναι το μέγεθος των καλύτερων χαρακτηριστικών που θα επιλεγούν. Ακέραιος αριθμός αν επιλεγεί η `selectkBest`, ποσοστό επί τοις 100 για `selectPercentile`.
5. “features\_window\_size\_id”. Αναφέρεται στο κλειδί του επιθυμητού χρονικού παραθύρου που επιλέγεται για χρήση.
6. “window\_segments\_size”. Σε περίπτωση που έχει τιμή μεγαλύτερη του 1, τότε συγχωνεύονται οι αντίστοιχοι συνεχόμενοι είσοδοι σε 1.
7. “epoch\_times”. Επιλογή των εποχών που θα χρησιμοποιηθούν σε περίπτωση νευρωνικού δικτύου.
8. “data\_split\_strategy”. Δίνεται η τιμή ‘time’ για την μέθοδο της ενότητας [4.2] και ‘None’ για την μέθοδο της [4.3].
9. “aggrageted\_dataset”. Σε περίπτωση συγκεντρωμένων χαρακτηριστικών σε ένα δείγμα για πολλές δραστηριότητες τότε παίρνει την τιμή `True`.

```
def train_model_via_features(self,
    model='ann',
    data_processing_algorithm='smote',
    feature_selection_method=None,
    feature_selection_size=50,
    features_window_size_id = '24hr',
    features_size= 'basic',
    window_segments_size=1,
    epoch_times=None,
    data_split_strategy='time',
    aggregated_dataset=False):
```

Εικόνα 8. Η διεπαφή της `train_model_via_features`

## 3.4 Η προεπεξεργασία δεδομένων

Η προεπεξεργασία των δεδομένων όπως και η εκπαίδευση και η αξιολόγηση των μοντέλων γίνεται στο αρχείο `network_manager.py` του φακέλου `models_manager`. Η προεπεξεργασία των δεδομένων αφορά την κανονικοποίηση των δεδομένων, τον χειρισμό των μη ισορροπημένων δεδομένων, την επιλογή των χαρακτηριστικών καθώς και χρησιμοποίηση ή όχι των χαρακτηριστικών των χρονοσειρών σε παράθυρα. Επίσης γίνεται και διαχωρισμός των δεδομένων σε δεδομένα εκπαίδευσης και δοκιμής (80% δεδομένα εκπαίδευσης – 20% δεδομένα δοκιμής).

### 3.4.1 Αντιμετώπιση μη έγκυρων τιμών

Στα διαθέσιμα δεδομένα υπάρχει η μέτρηση ποιότητας σήματος ηλεκτροκαρδιογραφήματος `ecg_signal_quality`, το οποίο διευκολύνει στην ανίχνευση και αντιμετώπιση μη έγκυρων τιμών. Λαμβάνει τιμές από 0 έως 255 και η μεγαλύτερη τιμή καθορίζει και αυξημένη ποιότητα σήματος. Τιμές χαμηλές καθιστούν αναξιόπιστες τις μετρήσεις και δυσχεραίνουν την διαδικασία ταξινόμησης. Για τον λόγο αυτό τέθηκε ως κατώφλι η τιμή 50. Έτσι κάτω από αυτό το κατώφλι, οι μετρήσεις απορρίπτονται και δεν λαμβάνονται υπόψιν. Καθώς οι μετρήσεις που αφορούν το ηλεκτροκαρδιογράφημα καταλαμβάνουν την πλειοψηφία των μετρήσεων απορρίπτεται ολόκληρο το χρονικό στιγμιότυπο.

Επιπλέον, διαπιστώθηκαν κάποιες τιμές για το `ecg_heart_rate`, οι οποίες αποκλίνουν εντελώς από τις φυσιολογικές τιμές για έναν ανθρώπινο οργανισμό. Οι τιμές αυτές όμως, δεν θα πρέπει να απορριφθούν εξαιτίας μόνο του γεγονότος αυτού, καθώς σε σπάνιες περιπτώσεις θα μπορούν να ισχύουν και να διευκολύνουν τον ταξινομητή. Για τον λόγο αυτό δεν απορρίπτονται άμεσα, αλλά γίνονται δεκτές μόνο αν υπάρχει ισχυρή ποιότητα σήματος. Η συνθήκη με την οποία απορρίπτονται αυτές οι τιμές είναι η παρακάτω:

`(ecg_heart_rate<30 and ecg_signal_quality<150) or (ecg_heart_rate<40 and ecg_signal_quality<90)`

### 3.4.2 Κανονικοποίηση δεδομένων

Έπειτα από τον διαχωρισμό των δεδομένων σε δεδομένα εκπαίδευσης και δοκιμής γίνεται η κανονικοποίηση των δεδομένων μέσω της μεθόδου `min-max normalization`. Για να έχουμε όσο το δυνατόν πιο ρεαλιστικά αποτελέσματα εφαρμόζεται αρχικά κανονικοποίηση στα δεδομένα εκπαίδευσης και στην συνέχεια αξιοποιώντας τον ίδιο scaler επαναλαμβάνεται η διαδικασία ξεχωριστά για τα δεδομένα δοκιμής. Η τεχνική κανονικοποίησης που αξιοποιείται είναι η `min-max normalization`, έτσι ώστε τα δεδομένα να τοποθετηθούν ανάμεσα στο 0 και το 1, μέσω της βιβλιοθήκης `sklearn`.

### 3.4.2 Επιλογή χαρακτηριστικών

Στην συνέχεια, αναλόγως από την είσοδο του χρήστη γίνεται επιλογή συγκεκριμένων χαρακτηριστικών ή όλων των διαθέσιμων, μέσω της παραμέτρου `feature_selection_method`. Αν η παράμετρος αυτή έχει τιμή «None» (δηλαδή δεν της δοθεί τιμή) τότε δεν εφαρμόζεται κάποια τεχνική επιλογής χαρακτηριστικών. Αντίθετα αν έχει την τιμή «selectkbest» εφαρμόζεται η τεχνική

selectkbest και ανάλογα με την παράμετρο `feature_selection_size` επιλέγονται αντίστοιχα οι «καλύτερες»  $K$  παράμετροι. Αντίστοιχα και για αν έχει την τιμή "selectPercentile". Στις δοκιμές που διενεργήθηκαν, χρησιμοποιήθηκαν ως συναρτήσεις βαθμολόγησης (score functions), η  $\chi^2$  και η Anova (μέσω των `chi2` και `f_classif` της βιβλιοθήκης `sklearn`).

### 3.4.3 Αντιμετώπιση μη ισορροπημένων δεδομένων

Για την αντιμετώπιση των μη ισορροπημένων δεδομένων, δηλαδή του γεγονότος ότι δεν διαθέτουμε ίσα δείγματα από κάθε κλάση εφαρμόζονται τεχνικές ανάλογα με την παράμετρο `data_processing_algorithm`. Οι διαθέσιμες τεχνικές και αυτές που εφαρμόστηκαν στις μετρήσεις είναι οι SMOTE, nearmiss, totemk links, μέσω της χρήσης βαρών καθώς και ένας υβριδικός αλγόριθμος ο οποίος αξιοποιεί συνδυαστικά μία oversampling (SMOTE) και μία undersampling (tomek links) τεχνική. Οι τεχνικές αυτές υλοποιούνται μέσω συναρτήσεων της βιβλιοθήκης `imblearn`. Είναι σημαντικό να τονιστεί ότι και εδώ η τεχνική αυτή εφαρμόζεται μόνο στα δεδομένα εκπαίδευσης, καθώς αν εφαρμοζόταν σε όλα τα δεδομένα, παρόλο που θα υπήρχε υψηλότερη ακρίβεια στα μοντέλα πρόβλεψης, δεν θα υπήρχε η απαιτούμενη ρεαλιστικότητα των αποτελεσμάτων.

## 3.5 Τα μοντέλα κατηγοριοποίησης

Κατά την ολοκλήρωση της προεπεξεργασίας δεδομένων υλοποιείται το επιθυμητό μοντέλο (ανάλογα με την τιμή της παραμέτρου "model"). Ορισμένα μοντέλα τα οποία υλοποιήθηκαν μέσω της βιβλιοθήκης `tensorflow`, εκτελούνται στην κάρτα γραφικών. Με τον τρόπο αυτό η διαδικασία της εκπαίδευσης, η οποία είναι ιδιαίτερα χρονοβόρα, επιταχύνεται σημαντικά. Οι διαθέσιμες επιλογές μοντέλων κατηγοριοποίησης είναι αυτές στις ακόλουθες υποενότητες.

### 3.5.1 Support-Vector Machines (SVM)

Για την χρήση αυτού δίνεται στην παράμετρο "model" η τιμή "svm". Η υλοποίηση του γίνεται μέσω της βιβλιοθήκης `thundersvm`. Το `thundersvm` είναι ένα πολύ γρήγορο υλοποιημένο λογισμικό για μηχανές διανυσμάτων υποστήριξης (SVMs). Ο βασικός λόγος είναι η χρήση σύγχρονων τεχνικών βελτιστοποίησης, παραλληλισμού και υλοποίησης με GPU. Παρόλα αυτά η χρήση SVMs όταν υπάρχουν πολλά δείγματα και χαρακτηριστικά απαιτεί μεγάλη υπολογιστική ισχύ και πόρων μνήμης.

Τα SVMs αποτελούν εξαιρετική επιλογή για την κατηγοριοποίηση δεδομένων. Η ικανότητά τους να διαχωρίζουν μη γραμμικά ασυμβίβαστα δεδομένα, η δυνατότητα χειρισμού υψηλών διαστάσεων και η ανθεκτικότητά τους στην υπερεκπαίδευση τα καθιστούν κατάλληλα για αναλύσεις ευπάθειας. Δεν επιλέχθηκαν όμως για τις περισσότερες δοκιμές καθώς παρά την παραλληλοποίηση που αναφέρθηκε προηγουμένως, ο μεγάλος όγκος των δεδομένων δεν επιτρέπει την εκτέλεση τους σε λογικά χρονικά πλαίσια με τους διαθέσιμους πόρους.

### 3.5.2 Feed-Forward Neural Network (FNN)

Για την χρήση αυτού δίνεται στην παράμετρο "model" η τιμή "ann". Το μοντέλο έχει μία είσοδο μεγέθους ίσο με το πλήθος των χαρακτηριστικών των δεδομένων εισόδου. Το μοντέλο αποτελείται από δύο κρυφά επίπεδα με αριθμό νευρώνων 300 και 100 αντίστοιχα, τα οποία χρησιμοποιούν την μη-γραμμική συνάρτηση ενεργοποίησης ReLU για την επεξεργασία των δεδομένων. Το τελευταίο επίπεδο του μοντέλου είναι ένα επίπεδο κλάσης το οποίο έχει 3 νευρώνες, αντιπροσωπεύοντας τις 3 πιθανές κατηγορίες πρόβλεψης. Για να επιτευχθεί η πρόβλεψη, χρησιμοποιείται η συνάρτηση ενεργοποίησης softmax, η οποία μετατρέπει τις εξόδους των νευρώνων σε πιθανότητες, ώστε να επιλεγεί η κατηγορία με την υψηλότερη πιθανότητα.

Για την εκπαίδευση του μοντέλου, χρησιμοποιείται η συνάρτηση απώλειας "sparse\_categorical\_crossentropy", η οποία είναι κατάλληλη για πολλαπλές κλάσεις. Επίσης, χρησιμοποιείται ο βελτιστοποιητής "adam" για την προσαρμογή των βαρών του μοντέλου κατά την εκπαίδευση. Το μοντέλο αξιολογείται χρησιμοποιώντας τη μετρική "accuracy", η οποία μετρά την ακρίβεια των προβλέψεων σε σχέση με τις πραγματικές κατηγορίες των δεδομένων ελέγχου.

Για να αποφευχθεί το overfitting, χρησιμοποιείται η τεχνική του "early stopping", όπου η εκπαίδευση διακόπτεται εάν η απόδοση στα δεδομένα ελέγχου δεν βελτιώνεται για μια προκαθορισμένη περίοδο (μέσω της μεταβλητής patienceModelStop) εποχών. Τα βάρη του μοντέλου αποθηκεύονται στη βέλτιστη κατάσταση, ώστε να μπορέσουν να χρησιμοποιηθούν για τις προβλέψεις στο τέλος της εκπαίδευσης.

Τέλος, η υλοποίηση γίνεται μέσω της TensorFlow με τρόπο τέτοιο έτσι ώστε να είναι εφικτή η εκτέλεση στην κάρτα γραφικών. Τα Feed-Forward Neural Network (FNN) επιλέχθηκαν για δοκιμές καθώς είναι μια καλή επιλογή για την κατηγοριοποίηση χρονικών ακολουθιών και χρονοσειρών σχετικά με την ευπάθεια όταν οι σχέσεις μεταξύ των δεδομένων και της ευπάθειας είναι απλές και γραμμικές, το σύνολο δεδομένων είναι μικρό, ή το χρονικό χαρακτηριστικό δεν είναι κρίσιμο για την κατηγοριοποίηση. Σε αυτές τις περιπτώσεις, τα Feed-Forward Neural Network μπορούν να παρέχουν αποτελεσματικές λύσεις χωρίς την πολυπλοκότητα των πιο προηγμένων αρχιτεκτονικών όπως τα LSTM δίκτυα. Για τους λόγους αυτούς εξετάζονται και αυτά στις δοκιμές για την αποτελεσματικότητά τους.

### 3.5.3 K-Nearest Neighbors (k-NN)

Για την χρήση αυτού δίνεται στην παράμετρο "model" η τιμή "knn". Η βιβλιοθήκη που χρησιμοποιείται είναι η sklearn. Ο ταξινομητής k-NN είναι ένας απλός αλγόριθμος μηχανικής μάθησης που μπορεί να χρησιμοποιηθεί για προβλήματα ταξινόμησης και πρόβλεψης. Το "k" αντιπροσωπεύει τον αριθμό των γειτόνων που θα χρησιμοποιηθούν για την κατηγοριοποίηση ενός δείγματος. Ως "k" επιλέχθηκε μετά από δοκιμές ο αριθμός 5.

Ο k-NN επιλέχθηκε καθώς είναι ένας χρήσιμος αλγόριθμος για την κατηγοριοποίηση δεδομένων σχετικά με την ευπάθεια, λόγω της ικανότητάς του να λαμβάνει υπόψη τη γειτνίαση και τις συσχετίσεις μεταξύ δεδομένων σε μια συγκεκριμένη περιοχή. Αν τα δεδομένα ευπάθειας εξαρτώνται από το περιβάλλον τους, όπως πλησιέστερες γειτονικές περιοχές, ο k-NN μπορεί να αναγνωρίσει τέτοιες σχέσεις και να βοηθήσει στην ανάλυση. Επιπλέον, είναι αποτελεσματικός για περιπτώσεις όπου η δομή των δεδομένων δεν είναι γνωστή εκ των προτέρων, καθώς δεν απαιτεί ιδιαίτερη προεπεξεργασία. Αυτές οι ιδιότητες τον καθιστούν χρήσιμο για την αντιμετώπιση των πολύπλοκων σχέσεων που συνδέονται με την ευπάθεια και την κατηγοριοποίηση των αντίστοιχων δεδομένων.

### 3.5.4 Gradient boosting

Ο αλγόριθμος Gradient boosting υλοποιείται όπως περιγράφεται στην ενότητα 2.5.3, με την βοήθεια της XGBoost. Η XGBoost (eXtreme Gradient Boosting) είναι μια βιβλιοθήκη λογισμικού ανοιχτού κώδικα που παρέχει ένα κανονικοποιητικό gradient boosting framework. Η βιβλιοθήκη της Python ονομάζεται xgboost. Αρχικά έγιναν κάποιες δοκιμές με τις defaults παραμέτρους του μοντέλου. Για την βελτίωση της ακρίβειας όμως οι παράμετροι αυτοί τροποποιήθηκαν ως εξής:

1. `n_estimators = 300`. Αύξηση του αριθμού των δέντρων σε 300.
2. `max_depth=6`, Αύξηση του βάθους του δέντρου.
3. `min_child_weight = 3`. Αύξηση του ελάχιστου αριθμού παρατηρήσεων για ένα παιδί (στο δέντρο)
4. `colsample_bytree = 0.8`. Αύξηση του ποσοστού χαρακτηριστικών ανά δέντρο.
5. `reg_alpha=0.01`. Εφαρμογή L1 κανονικοποίησης.
6. `reg_lambda=1.0`. Εφαρμογή L2 κανονικοποίησης.

Οι Gradient boosting μέθοδοι, όπως ο XGBoost επιλέχθηκαν καθώς αποτελούν ισχυρές επιλογές για την κατηγοριοποίηση δεδομένων σχετικά με την ευπάθεια. Η υψηλή τους ακρίβεια, η ικανότητά τους να διαχειρίζονται ανισορροπία κλάσεων, η δυνατότητα αντιμετώπισης πολύπλοκων συσχετίσεων, και η ευελιξία στην επεξεργασία χαρακτηριστικών, τα καθιστούν ιδανική επιλογή για αναλύσεις ευπάθειας, όπου η ακρίβεια και η απόδοση παίζουν κρίσιμο ρόλο.

### 3.5.5 Convolutional Neural Network (CNN)

Ο κατηγοριοποιητής με την μορφή Convolutional neural network (CNN) που χρησιμοποιήθηκε για τις συγκεκριμένες μετρήσεις είναι με την μορφή μιας διάστασης (1D Convolutional Layer – Conv1D). Είναι μια βασική δομή των Νευρωνικών Δικτύων, σχεδιασμένη για την ανάλυση χρονοσειρών ή άλλων μονοδιάστατων δεδομένων. Η Conv1D λειτουργεί παρόμοια με τον τρόπο που το συνελκτικό επίπεδο λειτουργεί σε εικόνες, αλλά αντί για 2D χώρο, εφαρμόζει τη συνέλιξη σε έναν μονοδιάστατο χώρο.

Όπως στα κλασικά συνελκτικά επίπεδα, η Conv1D χρησιμοποιεί φίλτρα (ή πυρήνες) για την ανίχνευση χαρακτηριστικών. Αυτά τα φίλτρα είναι μικρά παράθυρα που κυλούν κατά μήκος της χρονοσειράς και αντιλαμβάνονται μικρά υπο-πρότυπα. Όσον αφορά την συνέλιξη, τα φίλτρα στη Conv1D εκτελούν την πράξη της συνέλιξης κατά μήκος της χρονοσειράς. Σε κάθε βήμα κύλησης, το φίλτρο εφαρμόζεται σε ένα μικρό υπο-τμήμα της χρονοσειράς και υπολογίζεται ένας βαθμός συμφωνίας μεταξύ του φίλτρου και της υπο-χρονοσειράς.

Το CNN υλοποιείται μέσω της βιβλιοθήκης TensorFlow και έχει την παρακάτω δομή:

1. Το πρώτο στρώμα είναι ένα Conv1D στρώμα με 32 φίλτρα, που χρησιμοποιεί πυρήνα 3. Η συνάρτηση ενεργοποίησης ReLU (Rectified Linear Unit) εφαρμόζεται σε κάθε εξόδο του φίλτρου.
2. Ακολουθεί ένα επίπεδο MaxPooling1D, το οποίο εκτελεί υποδειγματοληψία με παράθυρο μήκους 2. Αυτό συμπυκνώνει τα χαρακτηριστικά και μειώνει τη διαστατικότητα των δεδομένων.
3. Στη συνέχεια, προστίθεται άλλο ένα Conv1D στρώμα με 64 φίλτρα και πυρήνα 3. Και πάλι, η συνάρτηση ενεργοποίησης ReLU εφαρμόζεται στις εξόδους.
4. Το δεύτερο επίπεδο MaxPooling1D εφαρμόζεται με παράθυρο μήκους 2 για ακόμα μεγαλύτερη συμπίεση των χαρακτηριστικών.

5. Το επίπεδο Flatten μετατρέπει την πολυδιάστατη έξοδο από τα προηγούμενα επίπεδα σε ένα επίπεδο μεγέθους που μπορεί να εισαχθεί σε ένα πλήρως συνδεδεμένο επίπεδο.
6. Ακολουθεί ένα πλήρως συνδεδεμένο επίπεδο με 128 νευρώνες και συνάρτηση ενεργοποίησης ReLU.
7. Για τη μείωση του υπερεκπαίδευσης, εφαρμόζεται ένα Dropout επίπεδο με ποσοστό απόκρισης 0.5, το οποίο απενεργοποιεί τυχαία το 50% των νευρώνων κατά την εκπαίδευση.
8. Το τελευταίο πλήρως συνδεδεμένο επίπεδο έχει τον αριθμό των κλάσεων της κατηγοριοποίησης ως αριθμό νευρώνων και χρησιμοποιεί τη συνάρτηση ενεργοποίησης Softmax για την εξαγωγή πιθανοτήτων κατηγορίας για κάθε είσοδο.

Τα Convolutional Neural Networks (CNN) αποτελούν εξαιρετική επιλογή για την κατηγοριοποίηση χρονικών ακολουθιών, όπως χρονοσειρές που σχετίζονται με την ευπάθεια. Η ικανότητά τους να αναγνωρίζουν χωρικά πρότυπα, να εξάγουν χρονικά χαρακτηριστικά και να αντιμετωπίζουν θορύβους τα καθιστούν μία καλή λύση για την ανάλυση της ευπάθειας σε δεδομένα χρονικών ακολουθιών. Για τους λόγους αυτούς επιλέχθηκαν για τις δοκιμές.

### 3.5.6 Long-Short Term Memory (LSTM) network

Το μοντέλο LSTM που υλοποιείται είναι ένα απλό αλλά αποτελεσματικό αναδραστικό νευρωνικό δίκτυο (RNN) . Υλοποιείται μέσω της βιβλιοθήκης tensorflow και η βασική αρχιτεκτονική είναι η εξής:

1. Επίπεδο LSTM (128 νευρώνες). Το πρώτο στρώμα είναι ένα αναδραστικό επίπεδο LSTM με 128 νευρώνες. Τα LSTM είναι ιδανικά για την επεξεργασία χρονοσειρών καθώς διατηρούν μνήμη για μεγάλες χρονικές αποστάσεις. Οι 128 νευρώνες αντιπροσωπεύουν τον αριθμό των εσωτερικών μονάδων του LSTM που θα χρησιμοποιηθούν για την αναγνώριση και εξαγωγή χαρακτηριστικών από τη χρονοσειρά.
2. Επίπεδο Dropout (0.15). Αμέσως μετά το επίπεδο LSTM, υπάρχει ένα επίπεδο Dropout με ποσοστό 0.15. Το επίπεδο Dropout απενεργοποιεί τυχαία νευρώνες κατά την εκπαίδευση, και αυτό βοηθά στη μείωση του υπερεκπαίδευσης.
3. Πλήρως Συνδεδεμένο Επίπεδο (64 νευρώνες, ReLU). Ακολουθεί ένα πλήρως συνδεδεμένο επίπεδο με 64 νευρώνες. Η συνάρτηση ενεργοποίησης ReLU (Rectified Linear Unit) εφαρμόζεται σε κάθε εξόδο του επιπέδου, βοηθώντας στην εισαγωγή μη γραμμικότητας στο μοντέλο.
4. Επίπεδο Dropout (0.15). Όπως και πριν, υπάρχει ένα επίπεδο Dropout για τη μείωση του υπερεκπαίδευσης.
5. Πλήρως Συνδεδεμένο Επίπεδο (Αριθμός κλάσεων, Softmax). Το τελευταίο πλήρως συνδεδεμένο επίπεδο έχει όσους νευρώνες είναι και ο αριθμός των κλάσεων στην κατηγοριοποίηση. Εφαρμόζεται η συνάρτηση ενεργοποίησης Softmax, η οποία μετατρέπει τις εξόδους σε πιθανότητες για κάθε κλάση.

Κάθε είσοδος στο μοντέλο αναπαριστά μια ακολουθία χρονικών στιγμιοτύπων. Επιλέχθηκε μήκος ακολουθίας 4 χρονικών βημάτων. Δηλαδή, αν η εξαγωγή χαρακτηριστικών εφαρμόζεται σε παράθυρα μήκους ενός λεπτού, τότε κάθε είσοδος στο lstm περιλαμβάνει τα 4 τελευταία στιγμιότυπα, συνολικού μήκους 4 λεπτών.

Τα Long-Short Term Memory (LSTM) δίκτυα επιλέχθηκαν για την κατηγοριοποίηση δεδομένων που σχετίζονται με την ευπάθεια λόγω των εξαιρετικών ικανοτήτων τους στη χειρισμό χρονοσειρών, τη διατήρηση μνήμης μακράς διάρκειας και τη δυνατότητα αντιμετώπισης πολύπλοκων συσχετίσεων. Η ικανότητά τους να προβλέπουν μελλοντικές επιπτώσεις και να αναγνωρίζουν μακροπρόθεσμα μοτίβα τα καθιστά χρήσιμα εργαλεία για αναλύσεις και

ανακαλύπτει στον τομέα της ευπάθειας. Επιπρόσθετα, δίνουν την δυνατότητα σε κάθε είσοδο να συμπεριλαμβάνει δεδομένα από το παρελθόν, δίνοντας την δυνατότητα για δεδομένα μεγαλύτερης χρονικής διάρκειας.

### 3.5.7 Εύρεση βέλτιστων παραμέτρων νευρωνικών δικτύων

Δίνοντας την τιμή "autotune" στην παράμετρο model ξεκινά μια προσπάθεια βελτιστοποίηση των παραμέτρων του νευρωνικού δικτύου με σκοπό την μεγαλύτερη δυνατή ακρίβεια. Αυτό επιτυγχάνεται μέσω της κλάσης MyHyperModel. Η κλάση αυτή παρουσιάζει μια προσεγγιστική μέθοδο για τη βελτιστοποίηση της αρχιτεκτονικής ενός νευρωνικού δικτύου μέσω της χρήσης του βελτιστοποιητή HyperBand σε συνδυασμό με τη βιβλιοθήκη Keras Tuner. Η κλάση "MyHyperModel" ενσωματώνει αυτήν την προσέγγιση, προσφέροντας έναν ευέλικτο τρόπο για την καθορισμό και τη βελτιστοποίηση των παραμέτρων ενός πολυεπίπεδου νευρωνικού δικτύου.

Η αρχική δομή του μοντέλου αποτελείται από ένα επίπεδο εισόδου με μέγεθος που καθορίζεται από τον αριθμό των χαρακτηριστικών εισόδου (input\_shape). Στη συνέχεια, διαπραγματεύεται διαφορετικές αρχιτεκτονικές επεκτείνοντας το μοντέλο με περισσότερα επίπεδα. Ο βελτιστοποιητής HyperBand εξετάζει ποικίλες παραμέτρους, όπως τον αριθμό των μονάδων (units) και τη συνάρτηση ενεργοποίησης, με σκοπό να εξερευνήσει τον χώρο των παραμέτρων και να προσαρμόσει το μοντέλο σύμφωνα με τις επιδόσεις του.

Το τελικό επίπεδο του μοντέλου αντιστοιχεί στον αριθμό των κλάσεων και χρησιμοποιεί την συνάρτηση ενεργοποίησης softmax για να προβλέψει την κλάση των δειγμάτων. Τέλος, πραγματοποιείται έλεγχος για "early stopping".

## 3.6 Μέγεθος παραθύρου χρονοσειρών

Σε χρονοσειρές με υψηλή συχνότητα δειγμάτων και μεγάλων μεγεθών είναι αναγκαίος ο διαχωρισμός των δεδομένων σε χρονικά παράθυρα και η εξαγωγή χαρακτηριστικών από αυτά. Τα πλεονεκτήματα αυτής της τεχνικής είναι τα εξής:

1. Δομική Πληροφορία: Ο διαχωρισμός σε παράθυρα επιτρέπει στο μοντέλο να λαμβάνει υπόψη τη δομή της χρονοσειράς και τις αλλαγές που μπορεί να συμβούν στον χρόνο. Κάθε παράθυρο λειτουργεί σαν ένα μικρό υποσύνολο της χρονοσειράς, και η εξαγωγή χαρακτηριστικών από κάθε παράθυρο δίνει πληροφορία για την εξέλιξη των δεδομένων σε αυτό το χρονικό διάστημα.
2. Περιορισμός της Πολυπλοκότητας: Ο διαχωρισμός σε παράθυρα μειώνει την πολυπλοκότητα της ανάλυσης. Αντί να εξετάζεται ολόκληρη η χρονοσειρά, επεξεργάζονται μικρά τμήματα, και αυτό επιτρέπει να γίνει εστίαση σε τοπικά χαρακτηριστικά και να μειωθεί ο αριθμός των ανεξάρτητων παραμέτρων που πρέπει να εξεταστούν.

Η επιλογή του κατάλληλου μεγέθους παραθύρου εξαρτάται από το πρόβλημα και τις εκάστοτε χρονοσειρές που αναλύουμε. Τα "μεγάλα" παράθυρα βοηθούν στην αξιοποίηση μακροπρόθεσμων τάσεων ενώ τα μικρά εστιάζουν κυρίως σε τοπικά χαρακτηριστικά. Στην συγκεκριμένη εργασία δίνεται η ευελιξία για την δημιουργία πολλών διαφορετικών χαρακτηριστικών με διαφορετικό μέγεθος παραθύρου με την αλλαγή μόνο μιας παραμέτρου.





## ΚΕΦΑΛΑΙΟ 4

### ΑΠΟΤΕΛΕΣΜΑΤΑ

Στις μετρήσεις, όπου ήταν εφικτό (ενότητα 4.3), πραγματοποιήθηκαν 3 διαφορετικές εκπαιδεύσεις και δοκιμές (cross-validation), με σκοπό την γενίκευση των αποτελεσμάτων. Σε κάθε εκπαίδευση-δοκιμή δίνεται τυχαίο δείγμα δεδομένων για εκπαίδευση και δοκιμή. Στην πρώτη δοκιμή εκτιμάται ο αριθμός των εποχών ο οποίος θα μείνει αμετάβλητος και στις επόμενες δοκιμές. Οι μετρικές που καταγράφονται είναι η ακρίβεια (accuracy), F1-score, precision και recall. Η μέθοδος της κλάσης NetworkManager που αναλαμβάνει να υλοποιήσει τα παραπάνω και να υπολογίζει τις απαιτούμενες μέσες (για τις 3 δοκιμές) μετρικές είναι η `evaluate_models_with_futures`. Δέχεται τις ίδιες παραμέτρους με την `train_model_via_features` και επιπρόσθετα την `num_of_tests`, η οποία καθορίζει τον αριθμό των δοκιμών.

#### 4.1 Τα δεδομένα που χρησιμοποιήθηκαν

Τα διαθέσιμα δεδομένα με τα οποία έγιναν οι δοκιμές που αναλύονται στις παρακάτω ενότητες είναι πραγματικά δεδομένα από συμμετέχοντες μέσω της συσκευής `wwsx`. Η συχνότητα των δειγμάτων είναι συνήθως 1 δείγμα ανά 40 milliseconds, ενώ αξίζει να αναφερθεί ότι τα δείγματα είναι για τυχαίες χρονικές περιόδους μέσα στην ημέρα. Σε κάθε δείγμα αναφέρεται η κατηγορία δραστηριότητας που εκτελεί ο συμμετέχοντας καθώς και μία ετικέτα κατηγοριοποίησης του δείκτη ευπάθειας. Από τα δεδομένα αυτά όμως όπως αναφέρθηκε και σε προηγούμενη ενότητα αξιοποιούνται μόνο όσα μπορούν να μετρηθούν από ένα «έξυπνο» κινητό ή ρολόι.

Οι συμμετέχοντες που υπάρχουν στα διαθέσιμα δεδομένα είναι 308. Υπάρχουν και των τριών κλάσεων κατηγοριοποίησης, με αρκετά λιγότερους όμως στην κατηγορία Frail. Η κατηγορία ευπάθειας του καθενός δεν είναι απαραίτητα σταθερή κατά την διάρκεια των ημερών των μετρήσεων.

#### 4.2 Χρήση τμημάτων με βάση την πάροδο του χρόνου

Αρχικά, διαχωρίστηκαν οι χρονοσειρές κάθε συμμετέχοντα σε παράθυρα του 1 λεπτού και για κάθε ένα από αυτά έγινε εξαγωγή χαρακτηριστικών. Για κάθε ένα μοντέλο κατηγοριοποίησης και κάθε μία τεχνική αντιμετώπισης των μη ισορροπημένων δεδομένων πραγματοποιήθηκαν 2 δοκιμές. Μία χωρίς επιλογή συγκεκριμένων χαρακτηριστικών και μία με την επιλογή των «καλύτερων» 95% μέσω της `selectPercentile`. Το σύνολο των παραθύρων χαρακτηριστικών που προέκυψαν διαχωρίζονται σε δεδομένα εκπαίδευσης και δοκιμής (με αναλογία 80%-20% αντίστοιχα). Ο διαχωρισμός των δεδομένων πραγματοποιείται με βάση την πάροδο του χρόνου και για κάθε συμμετέχοντα ξεχωριστά.

Αυτή η τεχνική διαθέτει ορισμένα πλεονεκτήματα. Αρχικά, διατηρεί τη χρονική σειρά των δεδομένων, η οποία είναι ζωτικής σημασίας για την ανάλυση χρονοσειρών. Είναι πιο κατάλληλη εάν υπάρχουν χρονικές εξαρτήσεις ή τάσεις στα δεδομένα. Μπορεί να βοηθήσει στην προσομοίωση πραγματικών σεναρίων όπου γίνονται προβλέψεις για μελλοντικά χρονικά σημεία. Επίσης, ανιχνεύοντας αλλαγή κατάστασης για κάποιον συμμετέχοντα από το Non-Frail προς το Frail, ουσιαστικά δίνεται και μία εκτίμηση για αύξηση των πιθανοτήτων πρόκλησης ενός δυσμενούς

γεγονότος.

Επιπλέον η τεχνική αυτή διαθέτει ορισμένα μειονεκτήματα. Εάν τα δεδομένα των συμμετεχόντων δεν είναι ισορροπημένα με την πάροδο του χρόνου, αυτή η προσέγγιση μπορεί να οδηγήσει σε άνιση κατανομή των συμμετεχόντων στα σετ εκπαίδευσης και δοκιμών. Επίσης, μπορεί να μην είναι τόσο κατάλληλο για γενίκευση του μοντέλου σε διαφορετικούς συμμετέχοντες

Αρχικά, χρησιμοποιήθηκαν οι «Full» μετρήσεις και τα "Full" χαρακτηριστικά όπως περιεγράφηκαν στη ενότητα [3.2], με εξαίρεση του "length" χαρακτηριστικού. Τα αποτελέσματα που προέκυψαν φαίνονται στον πίνακα 4.1.

#### 4.2.1 Χρήση χαρακτηριστικών ανά 1 λεπτό

Η εξαγωγή των χαρακτηριστικών των χρονοσειρών έγινε σε μήκους παραθύρων 1 λεπτού. Σε περίπτωση που γίνει αλλαγή κατάστασης κατά την διάρκεια του παραθύρου τότε μπορεί το παράθυρο να διαρκεί λιγότερο χρόνο. Απαραίτητη προϋπόθεση για την εξαγωγή χαρακτηριστικών σε ένα παράθυρο 1 λεπτού τέθηκε να υπάρχουν τουλάχιστον 125 δείγματα, τα οποία αντιστοιχούν αν είναι συνεχόμενα σε 5 δευτερόλεπτα. Αυτό συμβαίνει, διότι δεν θα ήταν δυνατόν να εξαχθούν συμπεράσματα για την ευπάθεια του ατόμου σε δεδομένα πολύ μικρών χρονικών διαστημάτων. Επίσης πολλές μετρήσεις πιθανόν να μην είχαν μεταβολές, κάνοντας την εξαγωγή χαρακτηριστικών ανούσια. Επομένως γίνεται εκτίμηση του δείκτη ευπάθειας ανά 1 λεπτό. Στα LSTM δίκτυα γίνεται και εκεί εκτίμηση ανά 1 λεπτό, όμως απαιτούνται ως είσοδο δεδομένα μήκους 4 χρονικών βημάτων. Άρα τουλάχιστον μία ακολουθία συνεχόμενων τεσσάρων λεπτών.

Model	Data Processing	Accuracy	F1-Score	Precision	Recall
<b>LSTM</b> time step = 4	Smote	83,39%	81,65%	81,30%	82,00%
	Tomek Links	83,95%	82,58%	83,26%	81,91%
	Smote+Tomek Links	83,71%	81,94%	81,33%	82,56%
	Class Weights	83,36%	82,57%	82,17%	82,97%
<b>XGBoost</b>	Smote	80,49%	78,47%	78,22%	78,22%
	Tomek Links	80,66%	78,39%	80,87%	76,06%
	Smote+Tomek Links	80,66%	78,37%	78,18%	78,56%
	Class Weights	80,95%	78,51%	81,97%	75,33%
<b>ANN</b>	Smote	74,28%	72,13%	70,26%	74,14%
	Tomek Links	76,68%	74,43%	76,84%	72,17%
	Smote+Tomek Links	74,91%	72,53%	70,53%	74,65%
	Class Weights	71,24%	68,65%	66,77%	70,64%

<b>KNN (k=5)</b>	Smote	75,97%	73,12%	71,14%	75,21%
	Tomek Links	78,06%	75,56%	77,29%	73,21%
	Smote+Tomek Links	76,02%	73,17%	71,21%	75,24%
	Class Weights	78,07%	75,59%	77,99%	73,33%
<b>CNN</b>	Smote	75,23%	73,48%	72,45%	74,54%
	Tomek Links	77,13%	73,48%	78,55%	69,02%
	Smote+Tomek Links	75,15%	73,04%	71,78%	74,35%
	Class Weights	72,87%	70,66%	69,16%	72,23%

Πίνακας 10. Αποτελέσματα για τμήματα χρόνου 1 λεπτού - Χωρίς επιλογή χαρακτηριστικών

Στον πίνακα 11 υπάρχουν τα αποτελέσματα που προέκυψαν για επιλογή χαρακτηριστικών, η οποία έγινε με βάση το 95% των «καλύτερων» χρησιμοποιώντας την μετρική  $\chi^2$ .

Model	Data Processing	Accuracy	F1-Score	Precision	Recall
<b>LSTM time step = 4</b>	Smote	83,65%	82,05%	81,48%	82,63%
	Tomek Links	83,61%	82,28%	82,93%	81,64%
	Smote+Tomek Links	83,30%	81,56%	80,67%	82,50%
	Class Weights	83,56%	82,51%	81,99%	83,04%
<b>XGBoost</b>	Smote	81,04%	78,86%	78,41%	79,32%
	Tomek Links	80,95%	78,72%	81,20%	76,39%
	Smote+Tomek Links	80,54%	78,83%	77,75%	79,94%
	Class Weights	80,85%	78,34%	81,64%	75,30%
<b>ANN</b>	Smote	75,55%	73,12%	71,13%	75,22%
	Tomek Links	77,49%	74,97%	77,19%	72,87%
	Smote+Tomek Links	75,24%	72,89%	71,02%	74,86%

	Class Weights	79,64%	79,59%	79,59%	79,59%
<b>KNN (k=5)</b>	Smote	76,23%	73,34%	71,39%	75,40%
	Tomek Links	78,09%	75,80%	77,48%	74,19%
	Smote+Tomek Links	76,07%	73,19%	71,23%	75,26%
	Class Weights	78,21%	75,8%	78,22%	73,53%
<b>CNN</b>	Smote	75,24%	73,18%	72,09%	74,30%
	Tomek Links	77,10%	74,38%	77,34%	71,64%
	Smote+Tomek Links	74,75%	72,51%	71,38%	73,68%
	Class Weights	71,11%	68,63%	66,83%	70,53%

Πίνακας 11. Αποτελέσματα για τμήματα χρόνου 1 λεπτού - Με επιλογή χαρακτηριστικών (SelectPercentile 95%)

Όπως παρατηρείται και από τους πίνακες 10 και 11 η καλύτερη ακρίβεια και το καλύτερο F1-score είναι τα εξής:

Μέγιστη Ακρίβεια: **83,95%** με LSTM μέσω Tomek Links, χωρίς επιλογή χαρακτηριστικών.

Μέγιστο F1-Score: **82,85%** με LSTM μέσω Tomek Links, χωρίς επιλογή χαρακτηριστικών.

Επίσης, γίνεται αντιληπτό ό,τι για τα διάφορα μοντέλα οδηγούν σε μεγαλύτερη ακρίβεια διαφορετικές προσεγγίσεις όσον αφορά τον αλγόριθμο προεπεξεργασίας των και δεδομένων καθώς και στην επιλογή των χαρακτηριστικών τους. Το γεγονός αυτό οδήγησε στην δοκιμή όλων των διαφορετικών συνδυασμών.

#### 4.2.2 Αναγωγή σε πρόβλημα 2 κλάσεων

Για να βελτιωθούν τα αποτελέσματα, αποφασίστηκε να δοκιμαστεί και μια άλλη προσέγγιση του προβλήματος. Αντί για ένα πρόβλημα που ανήκει σε τρεις διαφορετικές κατηγορίες, το πρόβλημα μετατράπηκε σε ένα πρόβλημα που ανήκει σε δύο κατηγορίες. Η ανάγκη για αυτή τη μετατροπή προέκυψε από το γεγονός ό,τι η κλάση Frail έχει αρκετά λιγότερα δείγματα από τις υπόλοιπες. Για τον λόγο αυτό οι κλάσεις Frail και Pre-Frail συγχωνεύονται και γίνονται νέες δοκιμές. Η αναγωγή αυτή παρ' όλο που οδηγεί σε μεγαλύτερη απόδοση προκαλεί απώλεια πληροφοριών. Πιθανόν, αυτές οι πληροφορίες να περιλαμβάνουν τη μεταβολή της ευπάθειας κατά τη διάρκεια του χρόνου, την ανίχνευση πρόωρων ενδείξεων ευπάθειας και τη διάκριση των ατόμων που βρίσκονται σε ενδιαμέση κατάσταση. Τα αποτελέσματα που προκύπτουν φαίνονται στου πίνακες 12 και 13.

Model	Data Processing	Accuracy	F1-Score	Precision	Recall
<b>LSTM</b> time step = 4	Smote	85,78%	85,69%	85,67%	85,70%
	Tomek Links	86,58%	86,45%	86,58%	86,36%
	Smote+Tomek Links	85,71%	85,61%	85,62%	85,60%
	Class Weights	85,83%	85,70%	85,80%	85,62%
<b>XGBoost</b>	Smote	83,16%	83,06%	83,03%	83,09%
	Tomek Links	83,15%	83,05%	83,03%	83,07%
	Smote+Tomek Links	82,57%	82,50%	82,45%	82,61%
	Class Weights	83,36%	83,20%	83,32%	83,12%
<b>ANN</b>	Smote	79,90%	79,65%	79,91%	79,52%
	Tomek Links	80,17%	79,96%	80,11%	79,86%
	Smote+Tomek Links	79,31%	79,28%	79,38%	79,57%
	Class Weights	79,65%	79,62%	79,62%	79,61%
<b>KNN (k=5)</b>	Smote	80,63%	80,56%	80,52%	80,69%
	Tomek Links	80,89%	80,79%	80,75%	80,86%
	Smote+Tomek Links	80,55%	80,51%	80,50%	80,70%
	Class Weights	80,99%	80,84%	80,88%	80,81%
<b>CNN</b>	Smote	79,96%	79,89%	79,85%	80,01%
	Tomek Links	80,59%	80,42%	80,48%	80,38%
	Smote+Tomek Links	80,68%	80,51%	80,57%	80,45%
	Class Weights	79,78%	79,71%	79,63%	79,79%

Πίνακας 12. Αποτελέσματα για τμήματα χρόνου 1 λεπτού - Χωρίς επιλογή χαρακτηριστικών (2 κλάσεις)

Model	Data Processing	Accuracy	F1-Score	Precision	Recall
<b>LSTM</b> time step = 4	Smote	85,66%	85,78%	85,56%	85,55%
	Tomek Links	85,80%	85,66%	85,79%	85,57%
	Smote+Tomek Links	85,79%	85,70%	85,69%	85,71%
	Class Weights	86,28%	86,18%	86,21%	86,15%
<b>XGBoost</b>	Smote	83,03%	82,94%	82,90%	83,04%
	Tomek Links	83,16%	83,05%	83,04%	83,06%
	Smote+Tomek Links	83,22%	83,15%	83,10%	83,26%
	Class Weights	83,31%	83,15%	83,27%	83,08%
<b>ANN</b>	Smote	79,90%	79,65%	79,91%	79,52%
	Tomek Links	79,94%	79,87%	79,81%	79,91%
	Smote+Tomek Links	78,50%	78,49%	78,74%	78,88%
	Class Weights	79,66%	79,61%	79,61%	79,61%
<b>KNN (k=5)</b>	Smote	80,86%	80,79%	80,75%	80,86%
	Tomek Links	80,91%	80,82%	80,77%	80,88%
	Smote+Tomek Links	80,65%	80,61%	80,60%	80,80%
	Class Weights	81,12%	80,97%	81,01%	80,94%
<b>CNN</b>	Smote	80,75%	80,66%	80,62%	80,72%
	Tomek Links	80,53%	80,30%	80,52%	80,18%
	Smote+Tomek Links	81,16%	80,96%	81,12%	80,87%
	Class Weights	79,72%	79,65%	79,62%	79,79%

Πίνακας 13. Αποτελέσματα για τμήματα χρόνου 1 λεπτών - Με επιλογή χαρακτηριστικών (SelectPercentile 95%) (2 κλάσεις)

Όπως παρατηρείται και από τους πίνακες 12 και 13 η καλύτερη ακρίβεια και το καλύτερο F1-score είναι τα εξής:

Μέγιστη Ακρίβεια: **86,58%** με LSTM μέσω Tomek Links, χωρίς επιλογή χαρακτηριστικών.

Μέγιστο F1-Score: **86,45%** με LSTM μέσω Tomek Links, χωρίς επιλογή χαρακτηριστικών.

Παρατηρούμε ότι το μοντέλο με τις υψηλότερα αποτελέσματα είναι το ίδιο όπως και στην ενότητα [4.2.1].

### 4.3 Χρήση τμημάτων με βάση την δραστηριότητα

Σε αυτή την ενότητα, εξετάζεται η προσέγγιση της εξαγωγής χαρακτηριστικών σε παράθυρα διάρκειας ίσης της κάθε δραστηριότητας. Επομένως για κάθε εναλλαγή της δραστηριότητας κάθε συμμετέχοντα πραγματοποιείται νέα εξαγωγή χαρακτηριστικών. Σκοπός αυτής της μεθόδου είναι η κατηγοριοποίηση ενός συμμετέχοντα κατά την ολοκλήρωση κάθε δραστηριότητας που πραγματοποιεί. Ο διαχωρισμός των δεδομένων γίνεται με την τεχνική K-fold Cross-Validation στο σύνολο των δεδομένων. Θεωρήσαμε ως k την τιμή 3. Δηλαδή πραγματοποιήθηκαν 3 διαφορετικοί διαχωρισμοί δεδομένων εκπαίδευσης και δοκιμής. Στον πίνακα 14 καταγράφονται οι μέσοι όροι (3 δοκιμές) για κάθε συνδυασμό επεξεργασίας δεδομένων και μοντέλου κατηγοριοποίησης.

Model	Data Processing	Accuracy	F1-Score	Precision	Recall
<b>XGBoost</b>	Smote	82,37%	79,97%	80,34%	79,64%
	Tomek Links	82,64%	79,82%	83,21%	77,51%
	Smote+Tomek Links	82,05%	79,64%	79,81%	79,81%
	Class Weights	82,50%	79,55%	83,69%	76,92%
<b>ANN</b>	Smote	79,74%	79,60%	79,60%	79,59%
	Tomek Links	80,17%	79,96%	80,11%	79,62%
	Smote+Tomek Links	79,31%	79,28%	79,38%	79,57%
	Class Weights	77,30%	74,03%	74,03%	72,27%
<b>KNN (k=5)</b>	Smote	76,69%	72,95%	71,00%	77,40%
	Tomek Links	79,33%	75,82%	77,86%	74,29%
	Smote+Tomek Links	76,02%	72,88%	70,95%	77,38%
	Class Weights	79,17%	75,60%	78,78%	73,50%



<b>CNN</b>	Smote	76,38%	73,13%	71,58%	75,54%
	Tomek Links	77,95%	73,40%	78,14%	70,82%
	Smote+Tomek Links	76,59%	73,29%	72,02%	75,26%
	Class Weights	72,53%	68,97%	67,44%	74,34%

Πίνακας 14 Αποτελέσματα για τμήματα ανά δραστηριότητα - Χωρίς επιλογή χαρακτηριστικών (3 κλάσεις)

Στον πίνακα 15 υπάρχουν τα αποτελέσματα που προέκυψαν για επιλογή χαρακτηριστικών, η οποία έγινε με βάση το 95% των «καλύτερων» χρησιμοποιώντας την μετρική  $\chi^2$ .

Model	Data Processing	Accuracy	F1-Score	Precision	Recall
<b>XGBoost</b>	Smote	82,39%	79,94%	80,38%	79,52%
	Tomek Links	82,34%	79,66%	83,13%	77,32%
	Smote+Tomek Links	82,46%	79,88%	80,09%	79,71%
	Class Weights	82,54%	79,81%	83,97%	77,15%
<b>ANN</b>	Smote	79,90%	79,65%	79,91%	79,52%
	Tomek Links	79,95%	79,85%	79,81%	79,91%
	Smote+Tomek Links	78,50%	78,49%	78,74%	78,88%
	Class Weights	77,49%	74,43%	72,62%	77,44%
<b>KNN (k=5)</b>	Smote	77,05%	73,39%	71,41%	77,64%
	Tomek Links	79,14%	79,70%	75,47%	73,69%
	Smote+Tomek Links	76,70%	72,88%	70,95%	77,38%
	Class Weights	79,62%	79,78%	76,21%	73,97%

CNN	Smote	76,36%	73,60%	72,20%	75,74%
	Tomek Links	78,33%	73,76^%	79,18%	70,95%
	Smote+Tomek Links	76,40%	73,29%	71,73%	75,65%
	Class Weights	72,63%	68,90%	67,31%	74,08%

Πίνακας 15 Αποτελέσματα για τμήματα ανά δραστηριότητα - Με επιλογή χαρακτηριστικών (SelectPercentile 95%) (3 κλάσεις)

Όπως παρατηρείται και από τους πίνακες 14 και 15 η καλύτερη ακρίβεια και το καλύτερο F1-score είναι τα εξής:

Μεγαλύτερη Ακρίβεια: **82,64%** με XGBoost μέσω Tomek Links, χωρίς επιλογή χαρακτηριστικών.

Μεγαλύτερο F1-Score: **79,97%** με XGBoost μέσω SMOTE, χωρίς επιλογή χαρακτηριστικών,

#### 4.3.2 Αναγωγή σε πρόβλημα 2 κλάσεων

Όπως και στην ενότητα [4.2.2] εξετάζεται η περίπτωση του προβλήματος των 2 κλάσεων, για το οποίο πραγματοποιούνται οι δοκιμές ακριβώς με τον ίδιο τρόπο όπως και προηγουμένως στην ενότητα [4.3]. Στα αποτελέσματα που προκύπτουν απεικονίζονται στους πίνακες 16 και 17.

Model	Data Processing	Accuracy	F1-Score	Precision	Recall
XGBoost	Smote	84,64%	84,25%	84,18%	84,32%
	Tomek Links	84,32%	83,95%	83,84%	84,09%
	Smote+Tomek Links	84,39%	83,95%	83,84%	84,09%
	Class Weights	84,55%	83,98%	84,37%	83,71%
ANN	Smote	81,10%	80,69%	80,56%	80,88%
	Tomek Links	82,00%	81,49%	81,53%	81,47%
	Smote+Tomek Links	81,21%	80,93%	80,76%	81,40%
	Class Weights	81,94%	81,52%	81,42%	81,66%

<b>KNN (k=5)</b>	Smote	81,36%	81,05%	80,87%	81,47%
	Tomek Links	82,05%	81,59%	81,53%	81,66%
	Smote+Tomek Links	81,27%	81,01%	80,85%	81,58%
	Class Weights	81,92%	81,34%	81,50%	81,22%
<b>CNN</b>	Smote	81,97%	81,63%	81,45%	81,95%
	Tomek Links	82,50%	81,99%	82,04%	81,95%
	Smote+Tomek Links	81,61%	81,26%	81,10%	81,59%
	Class Weights	82,10%	81,70%	81,63%	81,91%

Πίνακας 16. Αποτελέσματα για τμήματα ανά δραστηριότητα -Χωρίς επιλογή χαρακτηριστικών (2 κλάσεις)

Model	Data Processing	Accuracy	F1-Score	Precision	Recall
<b>XGBoost</b>	Smote	84,46%	84,03%	84,03%	84,03%
	Tomek Links	84,66%	84,20%	84,29%	84,13%
	Smote+Tomek Links	84,39%	84,02%	83,91%	84,16%
	Class Weights	84,49%	83,94%	84,25%	83,70%
<b>ANN</b>	Smote	81,44%	81,04%	80,97%	81,27%
	Tomek Links	81,35%	80,83%	80,84%	80,85%
	Smote+Tomek Links	81,71%	81,36%	81,19%	81,65%
	Class Weights	81,61%	81,23%	81,08%	81,48%
<b>KNN (k=5)</b>	Smote	81,39%	81,10%	80,92%	81,55%
	Tomek Links	81,99%	81,57%	81,47%	81,70%
	Smote+Tomek Links	81,36%	81,04%	80,89%	81,62%
	Class Weights	82,20%	81,63%	81,79%	81,51%

CNN	Smote	81,42%	81,03%	80,93%	81,27%
	Tomek Links	82,50%	81,99%	82,04%	81,95%
	Smote+Tomek Links	81,43%	81,14%	81,00%	81,60%
	Class Weights	81,51%	81,04%	81,13%	81,16%

Πίνακας 17. Αποτελέσματα για τμήματα ανά δραστηριότητα - Με επιλογή χαρακτηριστικών (SelectPercentile 95%) (2 κλάσεις)

Όπως παρατηρείται και από τους πίνακες 16 και 17 η καλύτερη ακρίβεια και το καλύτερο F1-score είναι τα εξής:

Μεγαλύτερη Ακρίβεια: **84,66%** με XGBoost μέσω Tomek Links, με επιλογή χαρακτηριστικών.

Μεγαλύτερο F1-Score: **84,25%** με XGBoost μέσω SMOTE, χωρίς επιλογή χαρακτηριστικών.



## ΚΕΦΑΛΑΙΟ 5

# ΣΥΜΠΕΡΑΣΜΑΤΑ ΚΑΙ ΜΕΛΛΟΝΤΙΚΕΣ ΕΠΕΚΤΑΣΕΙΣ

### 5.1 Συμπεράσματα

Συνοψίζοντας, είναι εφικτό να προβλεφθεί η ευπάθεια ενός ατόμου με βάση δεδομένα που αντικατοπτρίζουν την κίνηση και τη συμπεριφορά του, και αυτό επιτυγχάνεται με ικανοποιητικά αποτελέσματα, παρ' όλους τους περιορισμένους πόρους δεδομένων που ήταν διαθέσιμοι για την ανάλυση. Ωστόσο, είναι σημαντικό να σημειωθεί ότι αυτή η μέθοδος δεν μπορεί να αποτελεί το μοναδικό μέσο παρακολούθησης της υγείας ενός ατόμου. Η πρόβλεψη της ευπάθειας μπορεί να αποτελεί ένα επιπλέον εργαλείο που παρέχει επικουρική και συμβουλευτική επιτήρηση στους ηλικιωμένους και τα άτομα με χρόνιες ασθένειες. Συνεπώς, η ολοκληρωμένη φροντίδα της υγείας πρέπει να βασίζεται σε πολλαπλές πηγές πληροφοριών και παρακολούθησης.

Η μεγαλύτερη ακρίβεια επιτεύχθηκε με τα LSTM δίκτυα στις χρονικές ακολουθίες και με XGBoost στα παράθυρα δραστηριότητας. Στην περίπτωση των συνεχόμενων χρονικών ακολουθιών, μεγαλύτερο χρονικό παράθυρο (για την εξαγωγή χαρακτηριστικών) οδηγεί σε μείωση της ακρίβειας. Αυτό είναι αναμενόμενο καθώς με τον τρόπο αυτό συμπυκνώνεται περισσότερο η πληροφορία που εμπεριέχεται σε κάθε παράθυρο. Το XGBoost και ο KNN επίσης παρουσιάζουν αξιόλογη απόδοση και για τις δύο μορφές οργάνωσης των δεδομένων. Επομένως, η επιλογή του κατάλληλου μοντέλου εξαρτάται από τα χαρακτηριστικά των δεδομένων και τον συγκεκριμένο στόχο της κατηγοριοποίησης.

Η αναγωγή σε 2 κλάσεις (μέσω της συγχώνευσης της Pre-Frail με την Frail) όπως αναμενόταν προσφέρει αυξημένη απόδοση. Ωστόσο, η αύξηση αυτή στην απόδοση δεν κρίνεται αρκετή για να καλύψει τον ανεπιθύμητο αντίκτυπο της απαλοιφής της κλάσης Pre-Frail, καθώς κατά την αναγωγή αυτού του ενδιαμέσου επιπέδου, χάνονται πολύτιμες πληροφορίες που μπορούν να είναι χρήσιμες για την καλύτερη κατανόηση της κατάστασης ενός ατόμου.

Η χρήση τεχνικών επεξεργασίας δεδομένων όπως SMOTE και Tomek Links έχουν σημαντικό αντίκτυπο στην απόδοση των μοντέλων. Η SMOTE και η Tomek Links φαίνεται να βελτιώνουν τα αποτελέσματα τις περισσότερες φορές. Ο συνδυασμός τους όμως συνήθως δεν οδηγεί σε καλύτερα αποτελέσματα. Η καλή προεπιλογή χαρακτηριστικών δεν επέτρεψε στις τεχνικές επιλογής χαρακτηριστικών την αύξηση της ακρίβειας. Σημαντικό ρόλο επίσης έχει και η σωστή ανίχνευση και αντιμετώπιση των λανθασμένων δεδομένων. Με τον τρόπο αυτό αυξάνεται σημαντικά η απόδοση των μοντέλων.

## 5.2 Μελλοντικές επεκτάσεις

Η παρούσα διπλωματική εργασία προσφέρει μια ενδιαφέρουσα ματιά στον τομέα της κατηγοριοποίησης της ευπάθειας των ηλικιωμένων μέσω της χρήσης τεχνολογίας. Αναπτύσσοντας μια εφαρμογή σε Python, η οποία επιτρέπει την εκτέλεση διαφορετικών μεθόδων επεξεργασίας δεδομένων και κατηγοριοποίησης, η έρευνα αυτή ανοίγει τον δρόμο για πολλές μελλοντικές επεκτάσεις. Ορισμένες πιθανές μελλοντικές επεκτάσεις θα μπορούσαν να είναι οι εξής:

1. **Επέκταση του Όγκου των Δεδομένων:** Συγκέντρωση δεδομένων από περισσότερους συμμετέχοντες και χρονικές στιγμές αν είναι διαθέσιμα. Χρήση δεδομένων από γυροσκόπιο και μαγνητόμετρο για τις δεδομένες χρονικές στιγμές. Οι μετρήσεις αυτές εξάγονται επίσης από ένα «έξυπνο» ρολόι, αλλά στις παρούσες δοκιμές δεν ήταν διαθέσιμες. Περισσότερα δεδομένα συνήθως οδηγούν σε καλύτερα αποτελέσματα.
2. **Ενσωμάτωση Περισσότερων Χαρακτηριστικών:** Η εξαγωγή περισσότερων χαρακτηριστικών από τις χρονοσειρές. Για παράδειγμα, οι συντελεστές Γρήγορου Μετασχηματισμού Fourier (Fast Fourier Transform - FFT), η φασματική εντροπία (spectral entropy) για χαρακτηριστικά πεδίου συχνότητας, χαρακτηριστικά τα οποία πιθανόν να οδηγήσουν σε μεγαλύτερη απόδοση. Θα απαιτηθούν όμως περισσότεροι υπολογιστικοί πόροι και μεγαλύτερη επεξεργαστική ισχύ.
3. **Δοκιμή περισσότερων μοντέλων κατηγοριοποίησης:** Η δομή του κώδικα της εφαρμογής επιτρέπει την εύκολη προσθήκη νέων μοντέλων κατηγοριοποίησης. Για το λόγο αυτό, προτείνεται ως μελλοντική επέκταση η δοκιμή και διαφορετικών μοντέλων καθώς και παραμέτρων με σκοπό την εύρεση καλύτερης απόδοσης.
4. **Αξιοποίηση των αλλαγών του δείκτη ευπάθειας στην πρόβλεψη δυσμενούς γεγονότος:** Μέσω χρήσης δεδομένων από συμμετέχοντες που περιλαμβάνουν επίσης και πληροφορία για την υπάρξει δυσμενούς γεγονότος, είναι εφικτό να υλοποιηθούν μοντέλα πρόβλεψης δυσμενούς γεγονότος στο σύντομο μέλλον. Αυτό είναι εφικτό, με την παρατήρηση της μεταβολής του δείκτη ευπάθειας (από non-frail προς το frail) από τα μοντέλα που προτάθηκαν.

Όλες αυτές οι μελλοντικές προσθήκες μπορούν να υλοποιηθούν με βάση τον υπάρχοντα πηγαίο κώδικα και την υπάρχουσα βάση δεδομένων, στα πλαίσια μελλοντικής έρευνας, με σκοπό την δημιουργία αποτελεσματικότερων μοντέλων.

## ΒΙΒΛΙΟΓΡΑΦΙΑ

- [1] Β. Βούτσας, “Ανάπτυξη συστήματος μάθησης πολλαπλών στιγμιότυπων με χρήση συνελκτικών δικτύων” [Διπλωματική εργασία]. Τμήμα Μηχανικών Ηλεκτρονικών Υπολογιστών και Πληροφορικής, Πανεπιστημίου Πατρών, 2021
- [2] Π. Ακίνο-Ελλούλ, “Εκτίμηση/πρόγνωση κλινικών παραμέτρων ηλικιωμένων ανθρώπων από πολυμορφικά δεδομένα μεγάλου όγκου” [Διπλωματική εργασία]. Τμήμα Μηχανικών Ηλεκτρονικών Υπολογιστών και Πληροφορικής του Πανεπιστημίου Πατρών, Ιούλιος 2022
- [3] Δ. Κοκκονός, “Εκτίμηση ευθραυστότητας μέσω χώρο - χρονικών δεδομένων με μεθόδους μηχανικής μάθησης” [Μεταπτυχιακή Διπλωματική εργασία]. Διατμηματικό Προγράμμα Μεταπτυχιακών Σπουδών «Συστήματα Επεξεργασίας Πληροφορίας και Μηχανική Νοημοσύνη» (ΔΠΜΣ-ΣΜΗΝ) , Ιούνιος 2022
- [4] Γ. Καλούρης, “Activity Classification for older people using Convolutional Neural Networks” [Διπλωματική εργασία]. Τμήμα Μηχανικών Ηλεκτρονικών Υπολογιστών και Πληροφορικής, Πανεπιστημίου Πατρών, Ιούνιος 2018
- [5] Σ. Καλογιάννης, “Υλοποίηση ενός μοντέλου εικονικού ασθενή για ηλικιωμένους και εξαγωγή κλινικών προφίλ με ανάλυση συσταδοποίησης” [Μεταπτυχιακή Διπλωματική εργασία]. Τμήμα Μηχανικών Ηλεκτρονικών Υπολογιστών και Πληροφορικής, Πανεπιστημίου Πατρών, Νοέμβριος 2018
- [6] Ε. Ντούρου, “Εκτίμηση-πρόγνωση κλινικών παραμέτρων ηλικιωμένων ανθρώπων από πολυμορφικά δεδομένα” [Διπλωματική εργασία]. Τμήμα Μηχανικών Ηλεκτρονικών Υπολογιστών και Πληροφορικής, Πανεπιστημίου Πατρών, Οκτώβριος 2022
- [7] Α. Τσίρτση, “Πρόβλεψη κλινικού προφίλ ηλικιωμένων από δεδομένα πολλαπλών αισθητήρων με χρήση μεθόδων Μάθησης Πολλαπλών Στιγμιότυπων” [Διπλωματική εργασία]. Τμήμα Μηχανικών Ηλεκτρονικών Υπολογιστών και Πληροφορικής, Πανεπιστημίου Πατρών, Δεκέμβριος 2018
- [8] A. Papagiannaki, E.I. Zacharaki, G. Kalouris, S. Kalogiannis, K. Deltouzos, J. Ellul, V. Megalooikonomou, “Recognizing Physical Activity of Older People from Wearable Sensors and Inconsistent Data”, MDPI Journal, Sensors 2019, 19, 880, 20 February 2019
- [9] S. Kalogiannis , K. Deltouzos, E.I. Zacharaki, A. Vasilakis, K. Moustakas, J. Ellul, V. Megalooikonomou, “Integrating an openEHR-based personalized virtual model for the ageing population within HBase”, BMC Medical Informatics Decision Making, vol. 19, article 25, 28 January 2019
- [10] T. Tegou , I. Kalamaras, M. Tsipouras, N. Giannakeas, K. Votis and D. Tzovaras, “A Low-Cost Indoor Activity Monitoring System for Detecting Frailty in Older Adults”, MDPI Journal, Sensors 2019, 19, 452, 22 January 2019
- [11] T. Papastergiou, E.I. Zacharaki, V. Megalooikonomou, “Tensor Decomposition for Multiple Instance Classification of High-Order Medical Data”, Complexity, Volume 2018, article ID 8651930
- [12] M. G. Tsipouras, N. Giannakeas, T. Tegou, I. Kalamaras, K. Votis, D. Tzovaras, “Assessing the Frailty of Older People Using Bluetooth Beacons Data”, 14th International Conference on Wireless and Mobile Computing, Networking and Communications (WiMob 2018), , Limassol, Cyprus, DOI: 10.1109/WiMOB.2018.8589154



- [13] T. Tegou, I. Kalamaras, K. Votis, D. Tzovaras, “A low-cost room-level indoor localization system with easy setup for medical applications”, 11th IFIP Wireless and Mobile Networking Conference (WMNC 2018), Prague, Czech Republic, DOI: 10.23919/WMNC.2018.8480912
- [14] A. Papagiannaki, E.I. Zacharaki, K. Deltouzos, R. Orselli, A. Freminet, S. Cela, E. Aristodemou, M. Polycarpou, M. Kotsani, A. Benetos, J. Ellul, V. Megalooikonomou, “Meeting challenges of activity recognition for ageing population in real life settings”, 20th IEEE International Conference on e-Health Networking, Applications and Services (Healthcom), Ostrava, Czech Republic, DOI: 10.1109/HealthCom.2018.8531105
- [15] E. Pippa, E.I. Zacharaki, A.T. Özdemir, B. Barshan, V. Megalooikonomou, “Global vs local classification models for multi-sensor data fusion”, 10th Hellenic Conference on Artificial Intelligence, article 43, 1-5, Patras, Greece, DOI:10.1145/3200947.3201034
- [16] S. Kalogiannis, E.I. Zacharaki, K. Deltouzos, M. Kotsani, J. Ellul, A. Benetos, V. Megalooikonomou, “Geriatric group analysis by clustering non-linearly embedded multi-sensor data”, IEEE International Conference on INnovations in Intelligent SysTems and Applications (IEEE (SMC) INISTA 2018), Thessaloniki, Greece, DOI: 10.1109/INISTA.2018.8466269
- [17] I. Kalamaras, N. Kaklanis, K. Votis, D. Tzovaras, “Towards Big Data Analytics in Large-Scale Federations of Semantically Heterogeneous IoT Platforms”, 14th International Conference on Artificial Intelligence Applications and Innovations, Rhodes, Greece, DOI:10.1007/978-3-319-92016-0\_2
- [18] D. Vlachakis, E.I. Zacharaki, E. Tsiamaki, M. Koulouri, S. Raftopoulou, L. Papageorgiou, G.P. Chrousos, J. Ellul, V. Megalooikonomou, “Insights into the molecular mechanisms of stress and inflammation in ageing and frailty of the elderly”, Journal of Molecular Biochemistry, 6, 41–44, 2017
- [19] S. Karlos, N. Fazakis, S. Kotsiantis, K. Sgarbas, “An Empirical Study of Active Learning for Text Classification”, 21st International Conference on Knowledge-Based and Intelligent Information and Engineering Systems (KES 2017), 94–102, Marseille, France
- [20] A. A. Vasilakis, K. Vardis, G. Papaioannou and K. Moustakas, “Variable k-buffer using Importance Maps”, 38th Annual Conference of Eurographics (EG 2017), Lyon, France, DOI:10.2312/egsh.20171005
- [21] G. Drakopoulos and V. Megalooikonomou, “An Adaptive Higher Order Scheduling Policy With An Application To Biosignal Processing”, IEEE Symposium Series on Computational Intelligence (IEEE SSCI 2016), Athens, Greece, DOI: 10.1109/SSCI.2016.7849897
- [22] P. Ntanasis, E. Pippa, A. T. Özdemir, B. Barshan and V. Megalooikonomou, “Investigation of sensor placement for accurate fall detection”, 6th EAI International Conference on Wireless Mobile Communication and Healthcare (MobiHealth 2016), Milan, Italy, DOI:10.1007/978-3-319-58877-3\_30
- [23] G. Drakopoulos and V. Megalooikonomou, “Regularizing Large Biosignals with Finite Differences”, 7th International Conference on Information, Intelligence, Systems and Applications (IISA 2016), Chalkidiki, Greece, DOI: 10.1109/IISA.2016.7785346
- [24] G. Drakopoulos and V. Megalooikonomou, “A Graph Framework for Multimodal Medical Information Processing”, International Symposium on Mobile and Assistive Technology for Healthcare (MATH 2016) at the 8th International Conference on eHealth, Telemedicine, and Social Medicine (eTELEMED 2016), Venice, Italy
- [25] E. Pippa, Iosif Mporas and V. Megalooikonomou, “Feature Selection Evaluation for Light Human Motion Identification in Frailty Monitoring System”, 2nd International Conference on

Information and Communication Technologies for Ageing Well and e-Health (ICT4AWE 2016), Rome, Italy, DOI:10.5220/0005912200880095

[26] E. I. Zacharaki, K. Deltouzos, S. Kalogiannis, I. Kalamaras, L. Bianconi, C. Degano, R. Orselli, J. Montesa, K. Moustakas, K. Votis, D. Tzovaras, V. Megalooikonomou, FrailSafe: An ICT platform for unobtrusive sensing of multi-domain frailty for personalized interventions, , IEEE Journal of Biomedical and Health Informatics, 1557 - 1568 , April 2020, DOI: 10.1109/JBHI.2020.2986918

[27] Materia, University of Patras, FrailSafe Deliverable No: D7.4 Deliverable Title: Field trials report & Socioeconomic guidelines,, 14 June 2019

[28] Smartex, FrailSafe Deliverable No: D3.1 Definition of sensor components and communication strategy, 30 June 2016

[29] Γ. Καφτάνης, “Χρήση εξελικτικών νευρωνικών δικτύων και επεξεργασίας φυσικής γλώσσας για την πρόβλεψη ισοτιμιών συναλλάγματος” [Διπλωματική Εργασία]. Τμήμα Ηλεκτρολόγων Μηχανικών και Τεχνολογίας Υπολογιστών, Πανεπιστήμιο Πατρών, Ιούνιος 2021.

[30] S.Theodoridis, K.Koutroumbas. Βιβλίο: Αναγνώριση Προτύπων. Εκδόσεις Πασχαλίδης

[31] H. Jerome Friedman, “Greedy Function Approximation: A Gradient Boosting Machine”, Ann. Statist. 29 (5) 1189 - 1232, October 2001

[32] J. Zhanga, P. Wanga, R. Yanb, R. X. Gao, “Long short-term memory for machine remaining life prediction”. Department of Mechanical and Aerospace Engineering, Case Western Reserve University, Cleveland, Journal of Manufacturing Systems, 48, 78-86, July 2018